



UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

TOOL COLABORATIV SEMI-AUTOMAT DE ADNOTARE

LUCRARE DE LICENȚĂ

Absolvent: **Victor-Andrei GRIGORAȘ**

Coordonator **SL. Dr. Ing. Mircea-Paul MUREȘAN**
științific:

2026



UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

DECAN,
Prof. dr. ing. Vlad MUREȘAN

DIRECTOR DEPARTAMENT,
Prof. dr. ing. Rodica POTOLEA

Absolvent: **Victor-Andrei GRIGORAȘ**

TOOL COLABORATIV SEMI-AUTOMAT DE ADNOTARE

1. **Enunțul temei:** *Dezvoltarea unui instrument de adnotare vizuală semi-automat, asistat de Inteligență Artificială, cu capabilități de lucru colaborativ, pentru eficientizarea procesului de etichetare și reducerea timpului și a efortului.*
2. **Conținutul lucrării:** *Pagina de prezentare, introducere, obiectivele lucrării, studiu bibliografic, analiză și fundamentare teoretică, proiectare de detaliu și implementare, testare și validare, manual de instalare și utilizare, concluzii, bibliografie și anexe.*
3. **Locul documentării:** Universitatea Tehnică din Cluj-Napoca, Departamentul Calculatoare
4. **Consultanți:**
5. **Data emiterii temei:** 1 Octombrie 2025
6. **Data predării:** 10 Iulie 2026

Absolvent: _____

Coordonator științific: _____

**FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE**
DEPARTAMENTUL CALCULATOARE**Declarație pe propria răspundere privind
autenticitatea lucrării de licență**

Subsemnatul(a) _____, _____ legitimat(ă) cu

_____ seria _____ nr. _____
(conform copiei anexate prezentei declarații, copie sem-
nată și certificată "conform cu originalul"), autorul lucrării

elaborată în vederea susținerii examenului de finalizare a studiilor de licență la Facultatea de Automatică și Calculatoare, Programul de studiu _____ din cadrul Universității Tehnice din Cluj-Napoca, sesiunea _____ a anului universitar _____, declar pe proprie răspundere, că această lucrare este rezultatul propriei activități intelectuale, pe baza cercetărilor mele și pe baza informațiilor obținute din surse care au fost citate, în textul lucrării și în bibliografie.

Declar, că această lucrare nu conține porțiuni plagiate, iar sursele bibliografice au fost folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor.

Declar, de asemenea, că această lucrare nu a mai fost prezentată în fața unei alte comisii de examen de licență.

În cazul constatării ulterioare a unor declarații false, voi suporta sancțiunile administra- tive, respectiv, *anularea examenului de licență*. Sunt de acord ca, pe tot parcursul vieții, în cazul în care este necesar și se va dori verificarea autenticității lucrării mele să fiu identificat și verificat în baza datelor declarate de mine și conform copiei documentului de identitate menționat mai sus.

Data

Nume, Prenume

Semnătura

Instrucțiuni generale.

De citit înainte (această pagină se va elimina din versiunea finală):

1. Cele trei pagini anterioare (foaie de capăt, foaie sumar, declarație) se vor lista pe foi separate (nu față-verso), fiind incluse în lucrarea listată. Foaia de sumar (a doua) necesită semnătura absolventului, respectiv a coordonatorului. Pe declarație se trece data când se predă lucrarea la secretarii de comisie.
2. Pe foaia de capăt, se va trece corect titulatura cadrului didactic îndrumător, în engleză (consultați pagina de unde ați descărcat acest document pentru lista cadrelor didactice cu titlaturile lor).
3. Fiecare capitol începe pe pagină nouă.
4. Marginile paginilor nu se modifică.
5. Respectați restul instrucțiunilor din fiecare capitol.
6. Am inclus pachetul `hyperref` pentru a genera legături de navigare atât în document cât și la link-uri de web. Pentru listarea pe hârtie a fișierului pdf de comentarii linia care conține `%\hypersetup{hidelinks}` aflată în partea de început a fișierului principal `thesis_rom.tex`.

Cuprins

Capitolul 1	Introducere	1
1.1	Context și motivație	1
1.2	Domeniul și delimitarea temei	1
1.3	Soluția propusă și contribuții	2
1.4	Arhitectură colaborativă	2
Capitolul 2	Obiectivele proiectului	3
2.1	Introducere	3
2.2	Obiectivul general	3
2.3	Obiective principale	3
2.4	Obiective secundare	4
2.5	Cerințe funcționale și non-funcționale	5
2.5.1	Cerințe funcționale	5
2.5.2	Cerințe non-funcționale	5
Capitolul 3	Studiu bibliografic	6
3.1	Instrumente de adnotare semantică	6
3.2	Seturi de date și benchmark-uri	6
3.3	Arhitecturi de segmentare	7
3.4	Modele vizual-lingvistice	8
3.5	Tehnici de adnotare asistată	10
3.6	Evoluția pattern-urilor UI/UX în adnotare	12
3.7	Sincronizare colaborativă	12
3.8	Calitatea datelor și trasabilitate	13
3.9	Scalabilitate și confidențialitate	14
Capitolul 4	Analiză și fundamentare teoretică	16
4.1	Nume de secțiune	16
4.1.1	Nume de subsecțiune	16
Capitolul 5	Proiectare de detaliu și implementare	18
Capitolul 6	Testare și validare	19
Capitolul 7	Manual de instalare și utilizare	20
Capitolul 8	Concluzii	21
Bibliografie		22
Anexa A	Secțiuni relevante din cod	24
Anexa B	Alte informații relevante (demonstrații etc.)	25
Anexa C	Lucrări publicate (dacă există)	26

Capitolul 1. Introducere

1.1. Context și motivație

În ultimii ani, aplicațiile de viziune artificială au devenit uzuale în industrie și cercetare, iar calitatea lor depinde direct de seturile de date etichetate. Procesul de adnotare vizuală implică trasarea manuală a obiectelor în imagini, fie prin dreptunghiuri de încadrare, fie prin poligoane sau măști. Pentru seturi mari de date, această muncă este consumatoare de timp și necesită atenție constantă pentru a menține consistența între adnotări. În practică, multe proiecte întârzie sau cresc în cost tocmai din cauza efortului de etichetare.

Motivația lucrării pornește din nevoia de a reduce timpul și efortul necesare adnotării, fără a pierde controlul uman asupra rezultatului final. O abordare semi-automată, în care un model de inteligență artificială propune contururi sau măști, poate accelera semnificativ procesul. Utilizatorul rămâne totuși responsabil de validare și corectare, ceea ce păstrează calitatea datelor. În plus, exportul adnotărilor în formate standard ajută la integrarea rapidă a datelor în fluxuri de antrenare.

Un alt aspect important este colaborarea între mai mulți utilizatori. În proiectele reale, adnotarea se face de obicei în echipă, iar lipsa sincronizării duce la duplicarea muncii și la inconsistențe. Printr-un mecanism de lucru colaborativ, cu actualizări în timp real și gestionarea sesiunilor, echipa poate lucra pe același proiect în mod coordonat. Astfel, se obține un proces mai rapid, mai controlat și mai ușor de urmărit.

1.2. Domeniul și delimitarea temei

Lucrarea se încadrează în domeniul adnotării vizuale pentru date de tip imagine, cu accent pe segmentare și detecție de obiecte. Sunt vizate adnotări realizate prin dreptunghiuri, poligoane și măști, deoarece acestea acoperă cele mai folosite reprezentări în seturile de date moderne.

Domeniul ales include și administrarea etichetelor și a adnotărilor, astfel încât acestea să poată fi organizate și verificate ușor.

Datele rezultate sunt salvate într-un format intern și pot fi exportate în formate standard, precum COCO (Common Objects in Context) și YOLO (You Only Look Once). Astfel, seturile de date pot fi folosite ușor în fluxuri de antrenare, fără pași suplimentari de conversie. Structura de export este gândită pentru a păstra separarea între tipurile de adnotări și pentru a face reutilizarea cât mai simplă.

Tema este delimitată la un instrument desktop de adnotare, care integrează metode semi-automate prin apelarea unor modele externe. Modelul nu este antrenat în cadrul lucrării, ci este folosit ca suport pentru propunerea conturilor. Pentru segmentare asistată este folosit un model de tip Mask2Former, iar pentru detecție și segmentare completă se folosește un model de tip YOLOE.

Nu sunt urmărite subiecte precum optimizarea arhitecturilor de rețele neuronale, compararea extensivă a modelelor sau dezvoltarea unui serviciu cloud pentru adnotare. Accentul este pe realizarea unui instrument practic, ușor de folosit, local, care reduce efortul de etichetare și permite colaborarea eficientă între membri ai aceleiași echipe.

1.3. Soluția propusă și contribuții

Soluția propusă este o aplicație desktop dezvoltată în PyQt6, care oferă un flux de lucru complet pentru adnotarea imaginilor. Utilizatorul poate deschide un folder de imagini, alege rapid fișierele din listă și edita adnotările direct pe canvas. Interfața este organizată în panouri funcționale, astfel încât instrumentele de adnotare, lista de elemente și proprietățile acestora să fie accesibile fără a întrerupe procesul de lucru.

Canvasul este componenta centrală a interfeței. Acesta permite zoom și pan, desenarea de dreptunghiuri, poligoane sau măști, precum și selecția și modificarea elementelor existente. În plus, sunt disponibile ajustări vizuale ale imaginii pentru a crește claritatea în zonele dificil de adnotat. Acest mod de lucru ajută la păstrarea preciziei și reduce efortul în sarcinile repetitive.

Gestionarea adnotărilor se face printr-un manager central, care păstrează toate elementele asociate imaginii curente și oferă operații de adăugare, modificare sau ștergere. Managerul emite notificări către interfață atunci când apar schimbări, ceea ce asigură sincronizarea dintre starea internă și elementele afișate. Fiecare adnotare are un identificator propriu, fapt util pentru editare, export și colaborare.

Aplicația include facilități de tip *quality of life*, menite să reducă erorile și timpul pierdut. La închiderea aplicației sau la schimbarea imaginii, utilizatorul este întrebat dacă dorește să salveze modificările. În plus, aplicația include chat în timp real și suport de tip chatbot local pentru asistență.

Componenta de inteligență artificială este integrată prin AutoSeg și AutoMask, care rulează modele externe ca subprocese asincrone. Rezultatele sunt transformate în adnotări editabile, iar utilizatorul le poate corecta imediat. Astfel, aplicația combină propunerea automată cu controlul manual, obținând un echilibru între viteză și acuratețe.

Contribuțiile principale constau în integrarea unui flux complet de adnotare cu suport pentru segmentare semi-automată, organizarea clară a interfeței și mecanismele de sincronizare în colaborare. Rezultatul este un instrument practic, adaptat nevoilor de etichetare din proiecte reale.

1.4. Arhitectură colaborativă

Backend-ul aplicației este separat pe servicii dedicate pentru autentificare, chat și colaborare pe adnotări. Un reverse proxy direcționează cererile către serviciul corespunzător, iar mesageria facilitează schimbul de informații între module. Această separare permite dezvoltarea și testarea componentelor în mod independent, păstrând totuși un flux unitar pentru utilizator.

Sincronizarea se bazează pe două tipuri de comunicație. Prin REST, clientul listează sesiunile, obține un snapshot al stării curente și poate încărca sau descărca imagini temporare. Prin WebSocket, clienții primesc evenimente în timp real, precum crearea, actualizarea sau ștergerea adnotărilor. Când o imagine este actualizată într-o sesiune, ceilalți utilizatori primesc un eveniment de tip „image available” și sincronizează automat datele.

Modelul de colaborare este centrat pe sesiuni, fiecare sesiune având o stare curentă și o versiune a adnotărilor. Astfel, modificările sunt propagate rapid, iar utilizatorii văd același conținut fără conflicte majore. Autentificarea prin JWT (JSON Web Token) limitează accesul doar la utilizatorii autorizați, iar token-ul este salvat local pentru a evita relogarea repetată.

Capitolul 2. Obiectivele proiectului

2.1. Introducere

Acest capitol prezintă obiectivele proiectului. Ele sunt legate direct de problema adnotării vizuale și descriu ce se urmărește prin realizarea aplicației. Structura include obiectivul general, obiectivele principale și secundare, precum și cerințele funcționale și non-funcționale.

2.2. Obiectivul general

În mod obișnuit, adnotarea datelor vizuale este o muncă manuală, costisitoare și lentă, iar rezultatele pot fi influențate de oboseală și erori umane. Acest context creează nevoia unei soluții care să accelereze procesul, fără a pierde controlul asupra calității.

Obiectivul general al proiectului este dezvoltarea unei aplicații desktop de adnotare vizuală, semi-automată și colaborativă, care reduce timpul de etichetare și păstrează controlul utilizatorului asupra rezultatului final. Aplicația trebuie să ofere un flux de lucru complet, de la încărcarea imaginilor și navigarea rapidă între ele, până la editarea adnotărilor și exportul în formate standard. În mod explicit, trebuie să suporte adnotări de tip bounding box (dreptunghi), poligon și mască (image segmentation), pentru a acoperi scenariile uzuale de detecție și segmentare.

Gestionarea adnotărilor trebuie să fie clară și previzibilă, cu posibilitatea de selecție, editare și ștergere, astfel încât utilizatorul să poată corecta rapid erorile. Rezultatele trebuie să poată fi salvate și exportate în formate standard, pentru a fi folosite ușor în antrenarea modelelor. Prin integrarea unor modele externe pentru propuneri de segmentare și prin suportul pentru colaborare securizată între utilizatori, soluția urmărește să crească eficiența fără a compromite calitatea datelor.

2.3. Obiective principale

Obiectivele principale urmăresc să definească funcționalitățile cheie ale aplicației și modul în care acestea răspund cerințelor de adnotare. Fiecare obiectiv este formulat astfel încât să poată fi implementat și verificat concret.

- **Interfață de adnotare completă.** Realizarea unui canvas interactiv cu zoom și pan, care permite desenarea de adnotări de tip bounding box, poligon și mască. Interfața trebuie să susțină navigarea rapidă între imagini și un control vizual clar.
- **Gestionarea coerentă a adnotărilor.** Păstrarea unei structuri clare pentru etichete și elemente, cu identificatori unici, listare și operații de editare sau ștergere. Această structură reduce erorile și facilitează modificările ulterioare.
- **Export standardizat al datelor.** Oferirea de export în formatele COCO și YOLO, cu organizare predictibilă a fișierelor. Astfel, dataset-urile pot fi folosite direct în antrenare, fără conversii suplimentare.
- **Integrare AI semi-automată.** Folosirea AutoSeg și AutoMask pentru a genera propuneri de segmentare care pot fi corectate imediat de utilizator. Scopul este accelerarea procesului fără a compromite calitatea adnotărilor.

- **Modularizarea execuției AI.** Rularea modelelor ca aplicații separate, prin procese dedicate, pentru a izola erorile și a permite actualizări independente. Această abordare crește stabilitatea și flexibilitatea sistemului.
- **Colaborare în timp real.** Realizarea unui server separat pentru colaborare, cu suport de conectare și sesiuni comune, apoi sincronizare a evenimentelor de tip create, update și delete. Actualizarea imaginii între utilizatori se face prin REST și WebSocket pentru a evita duplicarea muncii.
- **Comunicare între utilizatori.** Oferirea unei interfețe de chat care permite schimbul de mesaje între utilizatori în timpul sesiunilor de lucru.
- **Securitate și acces controlat.** Autentificarea pe bază de JWT și păstrarea locală a token-ului pentru o experiență de lucru fluidă. Accesul la sesiuni și date trebuie să fie controlat și verificabil.
- **Evaluarea și selecția modelelor AI externe.** Testarea Mask2Former și YOLOE pe imagini de referință, cu măsurarea timpului de procesare și a calității rezultatelor. Alegerea finală trebuie justificată pe baza acestor rezultate.
- **Impachetarea și integrarea backend-urilor de inferență.** Folosirea unui script care facilitează build-uirea executabilului, pentru un export simplu și repetabil. Integrarea trebuie să permită conectarea ușoară a backend-urilor la aplicație.

2.4. Obiective secundare

Obiectivele secundare completează funcționalitățile principale prin îmbunătățirea experienței de utilizare și prin validări suplimentare ale componentelor AI și de colaborare.

- **Benchmarking pentru modele alternative.** Analizarea unor modele open-vocabulary (YOLO-World, LLMDet, SAM2) pentru a observa potențialul de generalizare și a justifica alegerea finală.
- **Validarea suportului local de tip VLM/LLM.** Compararea mai multor modele rulate local (Ollama) pentru a susține componenta de chatbot și a stabili un compromis calitate-viteză. Chatbotul are rolul de a ajuta utilizatorul cu întrebări și de a oferi sugestii pentru remedieri ale erorilor întâlnite.
- **Experiență de utilizare și prevenirea erorilor.** Confirmare la schimbarea imaginii și la închidere pentru a evita pierderea adnotărilor.
- **Persistența setărilor vizuale.** Salvarea preferințelor (grosime contur, dimensiune font, opacitate mască) între sesiuni.
- **Îmbunătățirea vizuală a imaginii.** Ajustări de luminozitate, contrast și gamma fără a altera datele originale.
- **Încărcare inteligentă a adnotărilor.** Asocierea automată a fișierelor JSON cu imaginea corespunzătoare.
- **Optimizarea serializării măștilor.** Compresie și reducerea volumului de date pentru fișiere mari.
- **Reducerea traficului în colaborare.** Împărțirea actualizărilor mari (ex. măști) în batch-uri și trimiterea lor prin WebSocket, pentru a evita închiderea prematură a conexiunii. Se aplică și deduplicarea evenimentelor.
- **Crosshair și ghidaj vizual.** Indicatori pentru precizie în adnotare și selectare.

2.5. Cerințe funcționale și non-funcționale

Pentru a susține obiectivele prezentate, proiectul are un set de cerințe funcționale și non-funcționale, sintetizate în tabelele de mai jos.

2.5.1. Cerințe funcționale

Cerință	Descriere scurtă
Încărcare și navigare imagini	Deschidere folder, listare rapidă și comutare între imagini.
Canvas de adnotare	Zoom, pan și trasare de bounding box, poligon și mască.
Editare adnotări	Selectare, modificare, ștergere, etichete și culori ușor de gestionat.
Import/Export	Salvare JSON și export COCO/YOLO cu structură predictibilă.
AI semi-automată	AutoSeg/AutoMask pentru propuneri rapide, corectabile imediat.
Modularizare AI	Rulare modele ca procese separate pentru izolare și actualizări.
Colaborare	Sesiuni, sincronizare create/update/delete prin REST și WebSocket.
Autentificare	Acces controlat cu JWT și token salvat local.
Comunicare	Chat între utilizatori și chatbot local pentru întrebări și erori.
Personalizare	Setări vizuale persistente și confirmare la închidere/schimbare.

2.5.2. Cerințe non-funcționale

Cerință	Descriere scurtă
Usabilitate	Interfață clară, operații frecvente accesibile rapid.
Performanță	Interfață responsivă în timpul procesării AI (asincron).
Fiabilitate	Validări pentru căi inexistente și mesaje clare de eroare.
Securitate	Protecția sesiunilor și a datelor prin token.
Integritate date	Exporturi consistente, fără pierderi de informație.
Scalabilitate	Mai mulți utilizatori pot lucra în aceeași sesiune.
Mentenabilitate	Arhitectură modulară pentru întreținere și extindere.
Extensibilitate	Adăugare de modele și formate noi fără refactor major.
Portabilitate	Rulare locală pe Windows cu configurare minimă.

Capitolul 3. Studiu bibliografic

Studiul bibliografic este organizat progresiv: de la instrumente și seturi de date existente, spre arhitecturi de segmentare și modele vizual-lingvistice, continuând cu tehnici de adnotare asistată și pattern-uri de interfață, și încheind cu sincronizare colaborativă, calitate și confidențialitate.

3.1. Instrumente de adnotare semantică

Instrumentele de adnotare reprezintă interfața dintre datele brute și seturile de date structurate necesare antrenării modelelor. Calitatea și eficiența acestor instrumente influențează direct volumul și consistența adnotărilor produse, cu efecte directe asupra performanței modelelor antrenate ulterior.

În raportul tehnic din 2017 al lui Breitenfeld și Muller-Birn se realizează o comparație sistematică a instrumentelor de adnotare semantică utilizate în contexte de cercetare, cu accent pe legarea conținutului la vocabulare controlate și baze de cunoștințe [1]. Autorii analizează uneltele după mai multe criterii: tipul de utilizator vizat, formatele de fișiere suportate, sursele de cunoștințe (RDF/SKOS), modul de interacțiune cu utilizatorul și contextul de rulare (aplicație web, desktop sau integrată în infrastructuri de cercetare). Analiza evidențiază diferențe clare între uneltele orientate spre utilizatori tehnici, care oferă mai multă flexibilitate, și cele care încearcă să includă experți de domeniu prin interfețe mai accesibile.

Concluzia principală este că majoritatea instrumentelor existente sunt construite cu utilizatorul tehnic în minte, iar suportul pentru colaborare în echipe și pentru trasabilitatea modificărilor rămâne limitat sau absent. Această lipsă îngreunează adopția în echipe interdisciplinare, unde adnotatorii au niveluri diferite de expertiză tehnică și unde istoricul deciziilor de adnotare trebuie să poată fi auditat. Deși lucrarea vizează adnotarea semantică și nu pe cea vizuală, observațiile privind uzabilitatea, colaborarea și trasabilitatea sunt direct relevante pentru proiectul de față, în care aceleași cerințe apar în procesul de etichetare a imaginilor. Din această perspectivă, studiul furnizează argumente solide pentru alegerea unui flux de lucru simplificat, orientat pe utilizator și cu suport explicit pentru colaborare.

3.2. Seturi de date și benchmark-uri

Seturile de date publice au jucat un rol central în standardizarea evaluării și în accelerarea progresului din domeniu. Ele definesc nu doar datele de antrenare și testare, ci și convențiile de adnotare, metricile de evaluare și nivelul de granularitate așteptat de la un instrument de etichetare.

PASCAL Visual Object Classes (VOC) reprezintă unul dintre primele benchmark-uri utilizate pe scară largă pentru detecție și segmentare [2]. Setul de date include etichete pentru 20 de clase comune de obiecte, oferind bounding box-uri pentru sarcina de detecție și măști de segmentare pentru edițiile care le includ. Competițiile anuale organizate în jurul PASCAL VOC au consolidat metrici standard, precum Average Precision (AP) calculat pe curba precizie-recall pentru detecție și Intersection over Union (IoU)/mean IoU

pentru segmentare. Aceste competiții au furnizat un cadru consistent de comparare a metodelor, de la descriptorii HOG cu clasificatoare SVM până la arhitecturile timpurii bazate pe rețele convoluționale profunde, precum R-CNN și variante. Importanța PASCAL VOC constă nu doar în datele în sine, ci în faptul că a impus practici de adnotare și protocoale de evaluare pe care comunitatea le-a urmat pe termen lung. Rămâne relevant ca reper metodologic și punct de referință în analiza evoluției practicilor de adnotare.

Microsoft COCO extinde semnificativ PASCAL VOC atât ca dimensiune, cât și ca complexitate, propunând un set de date de referință pentru detecție, segmentare și descriere de imagini în scene cotidiene cu obiecte multiple și parțial ocluzionate [3]. Colecția include peste 300.000 de imagini și mai mult de două milioane de instanțe adnotate, organizate pe 80 de clase obiect grupate în supercategorii. Anotările sunt detaliate și acoperă mai multe niveluri: segmentare pe instanță prin poligoane, bounding box-uri și descrieri textuale libere ale scenei. Procesul de adnotare a necesitat un efort considerabil, estimat la zece ori mai mare per imagine față de PASCAL VOC, ceea ce reflectă costul real al adnotărilor de calitate. Evaluarea utilizează metrici de precizie medie calculate la multiple praguri IoU (de la 0.5 la 0.95), pentru a reflecta mai realist calitatea localizării și nu doar detectarea obiectelor. COCO a standardizat protocoalele de evaluare și a devenit referința principală pentru compararea modelelor, influențând direct modul în care sunt concepute instrumentele moderne de adnotare.

Torrallba și Efros analizează bias-ul seturilor de date din recunoașterea vizuală și arată că modelele învață adesea caracteristici specifice colecțiilor de antrenare, nu concepte vizuale generale [4]. Autorii compară mai multe seturi de date cunoscute, PASCAL VOC, ImageNet, LabelMe, SUN09, Caltech101, MSRC, prin două tipuri de experimente: testul „Name That Dataset”, în care un clasificator trebuie să identifice colecția de origine a unei imagini, și teste de generalizare încrucișată, unde modelele antrenate pe o colecție sunt evaluate pe alta. Rezultatele sunt revelatoare: acuratețea scade semnificativ atunci când antrenarea și testarea se realizează pe surse diferite, iar bias-ul de selecție (ce imagini sunt incluse), bias-ul de captură (unghiuri, iluminare tipice) și bias-ul exemplarelor negative (ce obiecte apar în fundal) afectează direct robustețea modelelor în condiții reale. Deși studiul precede era rețelelor profunde și se bazează pe metode HOG/BoW cu SVM, concluziile privind bias-ul rămân valabile și în contextul arhitecturilor moderne, care pot amplifica aceste artefacte de distribuție. Pentru un instrument de adnotare colaborativă, lucrarea susține importanța fluxurilor de asigurare a calității, a consensului între adnotatori și a controlului activ asupra distribuției claselor și a exemplarelor negative în seturile construite.

3.3. Arhitecturi de segmentare

Arhitecturile de segmentare sunt componenta centrală a oricărui sistem de adnotare asistată. Evoluția lor, de la rețele complet convoluționale la arhitecturi bazate pe mecanisme de atenție, a permis creșterea preciziei și extinderea domeniului de aplicare, de la segmentare semantică simplă până la înțelegerea panoptică a scenei.

U-Net propune o arhitectură complet convoluțională pentru segmentare semantică, concepută inițial pentru imagini biomedicale în condiții cu puține date adnotate [5]. Structura în formă de U combină o cale de contractare (encoder) pentru extragerea caracteristicilor la rezoluții din ce în ce mai mici cu una de expansiune (decoder) pentru reconstrucția rezoluției originale, legate prin conexiuni de tip skip care transmit direct hărțile de caracteristici de la encoder la decoder. Aceste conexiuni skip sunt esențiale pentru păstrarea detaliilor spațiale fine, care s-ar pierde altfel în procesul de compresie.

Modelul utilizează o strategie overlap-tile pentru procesarea imaginilor de dimensiuni mari fără a fi limitat de memoria GPU, augmentare cu deformări elastice pentru a crește variabilitatea datelor de antrenare și o funcție de pierdere ponderată care accentuează granițele dintre obiectele adiacente. Evaluările pe datele ISBI de segmentare celulară au confirmat eficiența abordării chiar și cu seturi de antrenare de câteva zeci de imagini. U-Net a devenit un punct de referință în segmentarea semantică și a influențat numeroase arhitecturi ulterioare. Pentru proiect, modelul susține ideea de auto-segmentare rapidă în interfață, antrenare eficientă pe seturi mici create colaborativ și procesare pe dale pentru imagini de rezoluție mare.

Hariharan et al. propun un cadru unificat pentru detecție și segmentare la nivel de instanță, care prezice simultan bounding box-uri și măști pentru fiecare obiect din imagine [6]. Metoda extinde detectoarele bazate pe propuneri de regiuni prin adăugarea unui modul de predicție a măștii per instanță, oferind o înțelegere mai fină a scenei față de segmentarea semantică clasică, care nu diferențiază obiectele individuale din aceeași clasă. Relevanța pentru proiect este directă: adnotarea de instanțe presupune atât localizarea precisă a obiectelor, cât și delimitarea completă a conturilor lor, ceea ce justifică arhitecturi de instrumente care combină desenarea de bounding box-uri cu rafinarea ulterioară a măștilor de segmentare.

Kirillov et al. unifică segmentarea semantică și cea de instanțe într-o sarcină unică numită segmentare panoptică, în care fiecare pixel din imagine primește atât o categorie semantică (ex. drum, cer, mașină), cât și, pentru obiectele numărabile, un identificator de instanță unic [7]. Autorii introduc metrica Panoptic Quality (PQ), calculată ca produs între calitatea segmentării și calitatea recunoașterii, oferind un criteriu de evaluare unificat pentru ambele tipuri de regiuni. Formularea panoptică a impus cerințe mai stricte asupra adnotărilor, deoarece fiecare pixel trebuie atribuit unambiguu, fără zone neadnotate. Lucrarea a influențat arhitecturi ulterioare și este relevantă pentru proiect prin cerința de adnotări complete și consistente la nivel de imagine, fără suprapuneri sau lacune.

Mask2Former propune o arhitectură universală pentru segmentare, bazată pe clasificarea măștilor și pe mecanismul de object queries, care poate aborda simultan segmentarea semantică, de instanțe și panoptică folosind aceeași rețea [8]. Inovația principală este mecanismul de masked attention: spre deosebire de cross-attention global, fiecare query poate accesa doar pixelii din regiunea prezisă în iterația anterioară, reducând zgomotul de fundal și accelerând convergența. Decodorul rulează runde succesive de atenție pe hărți de caracteristici la rezoluții diferite ($1/32$, $1/16$, $1/8$), permițând modelului să rafineze progresiv predicțiile. Pentru a reduce consumul de memorie la antrenare, pierderile nu sunt calculate pe toți pixelii, ci pe un eșantion de puncte informative selectate adaptiv. Rezultatele arată performanță SOTA simultană pe COCO panoptic (PQ), COCO instance (AP) și ADE20K semantic (mIoU), cu convergență în aproximativ 50 de epoci față de sute de epoci la arhitecturi precedente. Limitările includ nevoia de antrenare separată per sarcină sau set de date și o performanță mai slabă pe obiecte foarte mici. Pentru proiect, Mask2Former este relevant prin posibilitatea de fine-tuning eficient pe seturi create colaborativ și prin generarea de propuneri cu focalizare locală, utilă pentru uneltele de pre-selectare și corecție rapidă.

3.4. Modele vizual-lingvistice

Modelele vizual-lingvistice au schimbat paradigma adnotării prin eliminarea necesității de a defini în avans un vocabular fix de clase. Capacitatea de a înțelege descrieri textuale libere și de a le lega de regiuni vizuale deschide noi posibilități pentru pre-adnotare

automată și interogare flexibilă a datelor.

CLIP introduce o metodă de învățare a reprezentărilor vizual-lingvistice prin antrenarea simultană a unui encoder vizual și a unui textual pe perechi imagine-text extrase de pe internet la scară de sute de milioane de exemple [9]. Obiectivul contrastiv maximizează similaritatea cosinusului pentru perechile imagine-text corecte și o minimizează pentru cele incorecte din cadrul aceluiași batch. Această abordare permite clasificare zero-shot: etichetele țintă sunt formulate ca prompturi textuale de tipul „A photo of a {label}.”, iar imaginea este clasată prin potrivire cu descrierea cea mai probabilă, fără a fi nevoie de exemple de antrenare specifice acelei sarcini. CLIP se dovedește competitiv cu modele supervizate pe ImageNet fără antrenare specifică și mai robust la schimbări de distribuție față de modelele clasice. Encoderul vizual a devenit un fundament pentru modelele de segmentare cu vocabular deschis și pentru sistemele multimodale care raționează simultan pe text și imagini. Pentru proiect, CLIP este relevant ca bază pentru interogări textuale flexibile în pre-adnotare și pentru sugestii rapide fără antrenare suplimentară, dar necesită verificare umană și control al bias-urilor transferate din datele web.

Liang et al. abordează o limitare specifică a CLIP la segmentare: performanța modelului scade semnificativ pe imagini mascate, din cauza diferenței de domeniu față de datele de pre-antrenare și a tokenilor de fundal neinformativi introduși de mascare [10]. Soluția propusă adaptează CLIP pe regiuni mascate prin construirea unui set de date zgomotos din subtitrările COCO și prin tehnica Mask Prompt Tuning (MPT), care înlocuiește tokenii de fundal mascați cu tokeni de prompt antrenabili, fie cu CLIP înghețat, fie cu fine-tuning complet. Modelul rezultat, OVSeg, obține rezultate SOTA în regim zero-shot pe mai multe benchmark-uri de segmentare cu vocabular deschis, incluzând ADE20K-150, ADE20K-847 și Pascal Context-459. Limitările includ influența claselor văzute la antrenare asupra propunerilor de măști și decalajul de performanță dintre clasele văzute și cele nevăzute. Pentru proiect, tehnica susține interogări textuale libere în adnotare, pre-adnotare automată din metadate textuale și adaptare eficientă cu resurse de calcul reduse, datorită numărului mic de parametri antrenabili din MPT.

YOLOE propune un model unificat, open-set și în timp real pentru detecție și segmentare, integrând prompturi textuale, vizuale și un mod fără prompt în aceeași arhitectură [11]. Pentru prompturi textuale, blocul RepRTA rafinează embedding-urile textuale la antrenare printr-o rețea de tip FFN, apoi re-parametrizează această rețea ca o convoluție 1×1 în capul de clasificare, eliminând complet costul suplimentar la inferență. Pentru prompturi vizuale, blocul SAVPE separă o ramură semantică (caracteristici agnostice față de prompt) de o ramură de activare (ponderi specifice promptului), agregându-le eficient pentru a produce un embedding vizual reprezentativ. În modul fără prompt, LRPC localizează toate obiectele din imagine fără un vocabular explicit, asociind ancorele relevante cu un vocabular extins doar la momentul inferenței. Rezultatele arată o reducere de circa trei ori a costului de antrenare față de YOLO-World, câștiguri consistente pe LVIS în regim zero-shot și viteză mai mare la inferență. Limitările includ dependența de un vocabular static în modul fără prompt și necesitatea generării de pseudo-măști cu SAM pentru antrenarea componentei de segmentare. Pentru proiect, YOLOE este relevant prin suportul multimodal, posibilitatea unui mod de auto-etichetare eficient și eliminarea costurilor suplimentare la rulare prin re-parametrizare, ceea ce facilitează deployment pe servere cu resurse limitate.

LLaVA propune o arhitectură care îmbină un encoder vizual (CLIP ViT-L/14) cu un model lingvistic de mari dimensiuni (Vicuna) printr-un strat de proiecție liniar, permițând dialogul vizual-textual detaliat bazat pe instrucțiuni naturale [12]. Autorii re-

zolvă lipsa datelor de antrenare de tip dialog vizual prin generarea automată de conversații om-AI condiționate de imagini cu ajutorul GPT-4, folosind doar metadatele imaginilor (subtitrări și bounding box-uri) ca input textual pentru GPT-4, fără a-i furniza imaginile direct. Modelul antrenat astfel atinge aproximativ 85.1% din performanța GPT-4 pe sarcini vizuale complexe și obține rezultate competitive pe benchmark-ul ScienceQA, care necesită raționament vizual-textual multi-pas. Limitările includ tendința la halucinații, inventarea de detalii care nu sunt prezente în imagine, și dificultăți la citirea textului mic sau a elementelor subtile de interfață, cauzate de limitările rezoluției encoderului vizual. Pentru proiect, LLaVA este relevant ca mecanism de asistență inteligentă: la trimiterea unei capturi de ecran din interfața de adnotare, modelul poate identifica elementele vizuale și răspunde la întrebări de tipul „Ce reprezintă zona selectată?” sau „De ce a fost propusă această etichetă?”, fără a efectua acțiuni automate în sistem.

DistilBERT reduce dimensiunea modelului BERT cu 40% prin distilarea cunoștințelor direct în faza de pre-antrenare, folosind o funcție de pierdere compusă din trei componente: distilare (imitarea distribuțiilor soft ale modelului profesor), modelare a limbajului (obiectivul clasic MLM) și aliniere a embedding-urilor intermediare prin similaritate cosinusă [13]. Rezultatul este un model mai rapid, cu un consum de memorie semnificativ redus, care păstrează aproximativ 97% din capacitatea de înțelegere a limbajului pe benchmark-ul GLUE. Principiul de distilare poate fi aplicat și altor modele lingvistice mari, oferind o cale generală spre modele mai eficiente. Pentru proiect, DistilBERT sau modele similare distilate sunt relevante pentru rularea locală a sarcinilor de procesare a limbajului natural, precum clasificarea intențiilor utilizatorului, completarea automată a etichetelor sau sugerarea categoriilor din vocabularul proiectului, reducând latența și costurile față de apelul unui model extern de dimensiuni mari.

3.5. Tehnici de adnotare asistată

Adnotarea asistată combină inferența automată a modelelor cu verificarea și corecția umană, reducând efortul de etichetare fără a renunța la controlul calității. Această secțiune prezintă principalele tehnici din literatura de specialitate, de la selecția inteligentă a exemplelor de adnotat până la generarea interactivă a măștilor.

Settles descrie în raportul său tehnic principiile și strategiile de active learning, arătând că un model poate obține performanțe ridicate cu un număr mult mai mic de exemple etichetate dacă selectează activ instanțele cele mai informative pentru adnotare [14]. Sunt acoperite trei scenarii principale: sinteza interogărilor (generarea de exemple artificiale), eșantionarea din flux (selectarea din datele care sosesc în timp real) și eșantionarea dintr-un rezervor (selectarea dintr-un pool fix de exemple neetichetate). Strategiile de interogare includ selecția bazată pe incertitudine (exemple aproape de granița de decizie), comitete de modele (exemple cu dezacord maxim între modele) și reducerea erorii sau varianței așteptate. În practică, active learning poate reduce substanțial efortul de etichetare, dar introduce provocări legate de costul variabil al etichetării diferitelor exemple, adnotatori cu erori și bias indus de strategia de selecție, care poate crea un set de antrenare nereprezentativ pentru distribuția reală a datelor. Pentru un instrument colaborativ de adnotare, aceste idei permit prioritizarea imaginilor sau a regiunilor cu cel mai mare aport informațional, evitând munca redundantă pe exemple deja bine reprezentate în model.

Tehnicile Grad-CAM (Gradient-weighted Class Activation Mapping) folosesc gradientul semnalului de pierdere față de activările ultimului strat convoluțional pentru a produce o hartă de căldură a regiunilor care au contribuit cel mai mult la decizia modelu-

lui [15]. Această hartă poate fi suprapusă ca overlay transparent peste imaginea originală, oferind o explicație vizuală intuitivă a predicției. Spre deosebire de metodele anterioare (ex. CAM clasic), Grad-CAM nu necesită modificarea arhitecturii rețelei și poate fi aplicat oricărui model convoluțional standard. Pentru proiect, aceste tehnici sunt utile ca mecanisme de transparență și asigurare a calității: pot explica de ce modelul a sugerat o anumită etichetă sau mască, pot evidenția erori de focalizare (modelul se concentrează pe fundalul tipic clasei, nu pe obiectul propriu-zis) și pot sprijini detectarea timpurie a bias-ului din datele de antrenare. Afișarea hărților ca overlay în interfața colaborativă facilitează validarea rapidă a sugestiilor automate și ghidează adnotatorii spre corectarea regiunilor problematice.

Polygon-RNN generează adnotări de instanțe ca poligoane produse secvențial de un model recurrent (RNN), ale cărui intrări sunt caracteristici vizuale extrase de un CNN aplicat pe decupajul obiectului [16]. Modelul prezice coordonatele vârfurilor pe o grilă discretizată, unul câte unul, și se oprește la un token special de final, transformând trăsarea completă a unui contur într-un proces de verificare și ajustare a câtorva vârfuri propuse. Utilizatorul poate corecta orice vârf greșit în timp real, iar modelul poate regenera secvența de la acel punct. Autorii raportează accelerări semnificative ale timpului de adnotare față de metoda manuală completă, menținând un acord ridicat cu adnotările de referință exprimat prin IoU. Pentru proiect, această abordare susține un flux de asistență AI cu feedback uman în buclă scurtă, în care interfața trebuie să permită corecturi rapide la nivel de vârf și să integreze imediat rezultatul corectat în forma finală fără a reporni întregul proces.

Deep Extreme Cut (DEXTR) reduce efortul de adnotare prin generarea unei măști de segmentare precise pornind de la doar patru puncte extreme ale obiectului, cel mai de sus, cel mai de jos, cel mai din stânga și cel mai din dreapta pixel al conturului [17]. Aceste patru puncte sunt codate ca hărți de densitate Gaussiană și concatenate cu imaginea originală ca al cincilea canal de intrare al rețelei, ghidând modelul să producă o mască focalizată pe zona de interes. Utilizatorul nu mai trasează poligoane complete, ci indică rapid limitele extreme ale obiectului în câteva click-uri, iar modelul produce o mască inițială de calitate comparabilă cu adnotarea manuală detaliată. Limitarea principală apare la obiecte puternic ocluzionate sau cu forme foarte neregulate, unde punctele extreme pot fi ambigue sau insuficiente pentru a delimita corect obiectul. Pentru proiect, DEXTR susține un flux de tipul „indicare sumară, apoi corecție punctuală”: masca inițială poate fi ajustată cu pensula sau prin re poziționarea unuia dintre punctele extreme pentru re-inferență rapidă. Comparativ cu Polygon-RNN, DEXTR reduce și mai mult interacțiunea inițială, dar depinde mai mult de calitatea inferenței modelului.

ScribbleBox propune un flux în două etape pentru adnotarea video de instanțe: componenta Curve-VOT urmărește obiectul de-a lungul secvenței printr-o curbă temporală parametrizată cu câteva puncte de control, iar Scribble-VOS rafinează măștile pe baza scribble-urilor propagate prin intermediul unui Graph Convolutional Network (GCN) [18]. Pe setul de referință DAVIS2017, metoda atinge 88.92% J&F (Jaccard and F-measure) cu circa 9.1 click-uri per secvență și necesită corecții explicite pe doar 4 cadre din întreaga secvență. Autorii furnizează și o analiză detaliată a latenței, relevantă pentru designul sistemului: propagarea măștilor la rezoluție 512px ajunge la circa 295 ms/cadru, la 256px circa 152 ms, iar cu cache la 256px circa 82 ms; propagarea scribble-urilor este de 15–28 ms, iar curve fitting și interacțiunea cu caseta sunt sub 15 ms fiecare. Limitarea principală este dependența de calitatea urmăririi inițiale: obiectele mici, parțial ocluzionate sau cu mișcări imprevizibile necesită mai multe puncte de control și corecții

manuale suplimentare. Pentru un instrument colaborativ, structura în două etape permite împărțirea sarcinilor pe niveluri de expertiză, iar latențele măsurate impun cerințe concrete de design: interfață asincronă cu indicatori de progres vizibili, cache persistent al rezultatelor intermediare și mod rapid (rezoluție mică) versus precis (rezoluție mare) selectabil de utilizator.

3.6. Evoluția pattern-urilor UI/UX în adnotare

Designul interfeței de adnotare influențează direct productivitatea adnotatorilor, consistența rezultatelor și capacitatea sistemului de a integra asistența automată. Evoluția acestor interfețe reflectă atât progresele din computer vision, cât și lecțiile acumulate din studiile de uzabilitate cu adnotatori reali.

Evoluția interfeței de adnotare reflectă trecerea de la interacțiunea manuală completă la cea asistată de modele. LabelMe, unul dintre primele instrumente web de adnotare vizuală la scară largă, permite editarea directă a poligoanelor prin operații de zoom, pan, adăugare și ștergere de noduri [19]. Această abordare oferă precizie ridicată și control deplin al adnotatorului, dar implică un cost de timp semnificativ pentru obiecte cu contururi complexe, mai ales când numărul de noduri al poligonului crește. De asemenea, LabelMe nu oferă mecanisme native de colaborare sau de asigurare a calității, ceea ce limitează utilizarea sa în echipe mari. Instrumente moderne precum ScribbleBox și CVAT au evoluat spre o paradigmă în care utilizatorul furnizează indicii brute (casete de delimitare sau scribble-uri), iar modelul generează rapid măști de calitate cu feedback aproape instant [18, 20]. Modele eficiente precum YOLOE susțin acest feedback în regim open-vocabulary, fără costuri mari de inferență și fără a necesita redefinirea vocabularului de clase [11].

CVAT (Computer Vision Annotation Tool) reprezintă unul dintre cele mai complete instrumente open-source de adnotare, structurând munca în ierarhii de proiecte, sarcini și job-uri, ceea ce reduce conflictele de acces și permite paralelizarea activității între adnotatori [20]. Interfața suportă multiple tipuri de adnotări (bounding box-uri, poligoane, cuboids, tracking video), iar integrarea cu modele de AI permite auto-adnotarea și rafinarea interactivă. Un flux în două etape similar cu ScribbleBox, casete brute generate de adnotatorii juniori, urmate de rafinarea măștilor complexe de către adnotatorii seniori, permite o alocare eficientă a sarcinilor pe niveluri de expertiză. Pattern-urile de tip issues și comentarii, combinate cu corecțiile non-distructive prin scribble-uri, reduc numărul de refaceri complete și accelerează ciclul de verificare. Practici suplimentare, precum consensul între adnotatori și honeypot-urile (sarcini cu adnotări cunoscute introduse pentru evaluarea calității), pot fi integrate pentru a măsura consistența și a detecta erori sistematice fără a întrerupe fluxul principal de lucru.

3.7. Sincronizare colaborativă

Colaborarea în timp real pe același set de adnotări ridică provocări tehnice specifice: mai mulți utilizatori pot modifica simultan aceleași obiecte, iar sistemul trebuie să reconcilieze aceste modificări fără a produce stări inconsistente sau conflicte ireparabile.

Sun et al. analizează diferențele fundamentale dintre OT (Operational Transformation) și CRDT (Commutative Replicated Data Type) printr-un cadru de transformare unificat care permite compararea lor pe baze comune [21]. Autorii introduc o distincție clară între starea vizibilă de utilizator (external state, ceea ce vede utilizatorul pe ecran) și structurile interne utilizate pentru sincronizare (internal state, reprezentările care permit

reconcilierea operațiilor concurente). Analiza arată că și CRDT, deși perceput adesea ca o soluție mai simplă, implică transformări indirecte și costuri suplimentare de memorie și calcul, ceea ce poate afecta performanța în sisteme interactive cu latență mică. Concluziile sugerează că, pentru aplicații cu un server central și colaborare în timp real cu număr moderat de utilizatori, un model operațional bazat pe propagarea și transformarea evenimentelor este mai predictibil, mai ușor de depanat și mai eficient decât un CRDT complex. Pentru un instrument de adnotare colaborativă, această perspectivă susține transmiterea operațiilor atomice (creare/modificare/ștergere de adnotări) în locul trimerii periodice a stării complete, reducând lățimea de bandă necesară și simplificând logica de reconciliere.

Arhitecturile event-driven facilitează colaborarea în timp real prin transmiterea asincronă a evenimentelor peste conexiuni persistente, decuplând producătorii de evenimente de consumatori. STOMP (Simple Text Oriented Messaging Protocol) oferă un protocol simplu, bazat pe text și pe principiul publicare/abonare, proiectat pentru a rula peste TCP sau WebSocket [22]. Protocolul definește un set minimal de frame-uri standard, CONNECT, SEND, SUBSCRIBE, MESSAGE, ACK/NACK, DISCONNECT, și separă explicit canalul de transport de logica de rutare a mesajelor, ceea ce facilitează integrarea cu brokeri de mesaje diferiți (ex. RabbitMQ, ActiveMQ) fără modificări în codul clientului. Simplitatea protocolului îl face accesibil pentru implementare atât în frontend (JavaScript), cât și în backend (Java, Python), asigurând interoperabilitate. Pentru proiect, STOMP susține broadcast instant al modificărilor pe canvas, mecanisme de locking al obiectelor editate (pentru a preveni conflictele), notificări de prezență și sincronizarea comentariilor și a modificărilor de stare ale sarcinilor.

3.8. Calitatea datelor și trasabilitate

Calitatea adnotărilor este un factor determinant pentru performanța modelelor antrenate pe aceste date. Un sistem de adnotare colaborativă trebuie să ofere nu doar instrumentele de etichetare, ci și mecanismele de verificare, audit și trasabilitate care garantează că adnotările sunt corecte, consistente și reproductibile.

Lucrarea „Counting on Consensus” oferă un ghid practic și teoretic pentru alegerea metricilor de acord între adnotatori (Inter-Annotator Agreement, IAA), subliniind că procentul brut de acord este înșelător în clasele dezechilibrate, deoarece nu corectează acordul care ar apărea prin pură coincidență [23]. Lucrarea recomandă metrici corectate pentru hazard, precum Cohen’s Kappa (pentru doi adnotatori) sau Krippendorff’s Alpha (pentru mai mulți adnotatori și diverse scale de măsurare). Pentru etichete continue sau ordonate sunt relevante variante precum Kappa ponderată, care penalizează diferit dezacordurile în funcție de gravitatea lor, sau ICC (Intraclass Correlation Coefficient), utilizat frecvent în evaluările clinice. Pentru adnotări structurate, cum sunt măștile de segmentare, sunt mai potrivite măsuri de suprapunere spațială (F1/Dice) și metrici de frontieră care penalizează erorile de localizare. Deși focusul lucrării este pe NLP, principiile se transferă direct la adnotarea de imagini: sistemul poate calcula IAA pe etichete de clasă și pe suprafețele măștilor, poate semnală automat cazurile cu dezacord ridicat între adnotatori pentru revizie și poate impune raportarea intervalelor de încredere în loc de valori punctuale, sprijinind un pipeline de asigurare a calității bazat pe consistență măsurabilă.

Standardul W3C PROV-DM oferă un model formal și interoperabil pentru descrierea provenienței entităților digitale, adică a modului în care acestea sunt create, transformate și utilizate [24]. Modelul introduce trei concepte fundamentale, entitate (un obiect

digital sau o adnotare), activitate (un proces care transformă sau generează entități) și agent (o persoană sau un sistem care inițiază activități), și relații semantice precum *wasGeneratedBy* (entitate produsă de o activitate), *wasDerivedFrom* (entitate derivată din alta) și *wasAssociatedWith* (activitate asociată unui agent). Aceste relații permit reconstruirea completă a istoricului unei adnotări: cine a creat-o, când, pe baza căror date de intrare, cine a modificat-o ulterior și de ce. În contextul adnotării colaborative cu componente automate, PROV-DM este esențial pentru a distinge între adnotările produse de utilizatori umani și cele generate de modele, pentru auditarea calității și pentru reproducibilitatea experimentelor.

Metadatele structurate ale unui sistem de adnotare, proiecte, sarcini, utilizatori, etichete, istoricul modificărilor, comentarii, sunt potrivite pentru un sistem de gestiune a bazelor de date relaționale (RDBMS) precum PostgreSQL, care oferă tranzacții ACID, control al concurenței multi-utilizator prin MVCC și indexare eficientă pentru interogări complexe [25]. Fișierele media (imagini, videoclipuri) sunt stocate separat în sisteme de fișiere locale sau în object storage distribuit și sunt referențiate prin chei sau URL-uri în baza de date, asigurând o separare clară între datele structurate, supuse unui management strict al consistenței, și cele nestructurate, supuse altor cerințe de scalabilitate. Această arhitectură este standard în sistemele moderne de adnotare și permite scalarea independentă a celor două componente. În proiectul de față, PostgreSQL este utilizat în principal pentru autentificare și managementul sesiunilor, dar rămâne opțiunea optimă pentru extensiile viitoare care vor necesita organizarea metadatelor la o scară mai mare.

3.9. Scalabilitate și confidențialitate

Pe măsură ce sistemele de adnotare colaborativă cresc în dimensiune și în numărul de utilizatori concurenți, apar provocări suplimentare legate de distribuirea eficientă a sarcinilor de calcul și de protecția datelor sensibile ale utilizatorilor.

Neurosurgeon propune o schemă de inteligență colaborativă cloud-edge, în care o rețea neuronală adâncă este partiționată la un punct optim, cu straturile inițiale executate local pe dispozitivul utilizatorului și straturile finale executate pe serverul cloud [26]. Modelul profiler estimează timpul de execuție și consumul de energie pentru fiecare strat al rețelei, atât în execuție locală, cât și în cloud, luând în calcul și costul transferului activărilor intermediare (care depinde de lățimea de bandă disponibilă). Pe baza acestor estimări, sistemul alege dinamic stratul L la care activarea este transmisă către server, optimizând fie latența totală, fie consumul energetic al dispozitivului. Evaluările pe mai multe arhitecturi CNN arată că această partiționare adaptivă reduce semnificativ latența end-to-end față de rularea completă în cloud (eliminând latența de transfer a imaginii brute) și față de rularea completă locală (eliminând costul straturilor profunde). Pentru proiect, această abordare permite rularea locală a straturilor ușoare pentru feedback vizual rapid (proponeri brute de bounding box-uri sau segmentări grosiere), delegând straturile costisitoare de rafinare către backend, cu o experiență interactivă fluidă adaptivă la calitatea conexiunii de rețea a fiecărui utilizator.

Lucrarea „Privacy-Preserving Collaborative Learning” propune o schemă de învățare colaborativă cu protecție diferențiată la nivel de participant, în care fiecare agent poate defini propriul buget de confidențialitate prin adăugarea de zgomot Gaussian calibrat în procesul de agregare a parametrilor modelului [27]. Autorii utilizează cadrul zCDP (zero-Concentrated Differential Privacy) pentru a cuantifica și a compune garanțiile de confidențialitate pe parcursul multiplelor runde de antrenare, oferind garanții formale atât pentru transmisia locală (uplink), cât și pentru modelul global distribuit (down-

link). Analiza de convergență demonstrează că schema atinge o soluție optimă chiar și cu niveluri ridicate de perturbație, cu condiția calibrării corecte a zgomotului. Conceptele din lucrare fundamentează politicile de autentificare și autorizare necesare într-un sistem de adnotare multi-tenant cu date sensibile, unde izolarea strictă între proiectele și utilizatorii diferiți este o cerință de bază. Arhitectura susține și un flux de pre-etichetare pe dispozitiv (on-device), în care serverul central primește doar actualizările de model ofuscate, fără acces direct la imaginile brute ale utilizatorilor, o proprietate importantă în domeniile cu cerințe stricte de confidențialitate, precum medicina sau datele personale.

Capitolul 4. Analiză și fundamentare teoretică

Împreună cu următoarele 2 capitole trebuie să reprezinte aproximativ 70% din total.

Scopul acestui capitol este de a explica principiile funcționale ale aplicației implementate. Aici se va descrie soluția propusă dintr-un punct de vedere teoretic - explicați și demonstrați proprietățile și valoarea teoretică:

- algoritmi utilizați sau propuși
- protocoale utilizate
- modele abstracte
- explicații/argumentări logice ale soluției alese
- structura logică și funcțională a aplicației.

NU SE FAC referiri la implementarea propriu-zisă.

NU SE PUN descrieri de tehnologii preluate cu copy-paste din alte surse sau lucruri care nu țin strict de proiectul propriu-zis (materiale de umplură).

4.1. Nume de secțiune

4.1.1. Nume de subsecțiune

Fiecare tabel introdus în lucrare este numerotat astfel: Tabel x.y, unde x reprezintă numărul capitolului, iar y numărul tabelului din capitol. Se lasă un rând liber între tabel și paragraful anterior, respectiv posterior (tabelul 4.1).

Tabela 4.1: Rezultate

Case	Method#1	Method#2	Method#3
1	50	837	970
2	47	877	230
3	31	25	415

Fiecare figură introdusă în text este citată (de ex: în figura x.y este prezentată ...) și numerotată. Numerotarea se face astfel Figura x.y unde x reprezintă numărul capitolului iar y numărul figurii în acel capitol. Numerotarea o face automat latex pe baza etichetei (`\label{}`).

Referirea unei figuri se face cu `\ref{}`. De exemplu, referința: figura 4.1.




Figura 4.1: Numele figurii

Capitolul 5. Proiectare de detaliu și implementare

Împreună cu capitolul **precedent** și cel **următor** trebuie să reprezinte aproximativ 70% din total.

Scopul acestui capitol este de a documenta aplicația dezvoltată în așa fel încât dezvoltarea și întreținerea ulterioară să fie posibile. Cititorul trebuie să identifice funcțiile principale ale aplicației din ceea ce este scris aici. Capitolul ar trebui să conțină (nu se rezumă neapărat la):

- schema generală a aplicației
- descrierea fiecărei componente implementate, la nivel de modul
- diagrame de clase, clase importante și metode ale claselor importante.
- diagrame de baze de date

Capitolul 6. Testare și validare

Împreună cu cele două capitole **precedente** trebuie să reprezinte aproximativ 70% din total.

Capitolul 7. Manual de instalare și utilizare

În secțiunea de Instalare trebuie să detaliați resursele software și hardware necesare pentru instalarea și rularea aplicației, precum și o descriere pas cu pas a procesului de instalare.

Instalarea aplicației trebuie să fie posibilă pe baza a ceea ce se scrie aici.

În acest capitol trebuie să descrieți cum se utilizează aplicația din punct de vedere al utilizatorului, fără a menționa aspecte tehnice interne.

Folosiți capturi ale ecranului și explicații pas cu pas ale interacțiunii.

Folosind acest manual, o persoană ar trebui să poată utiliza produsul vostru.

[Între 1 și 5 pagini.](#)

Capitolul 8. Concluzii

Între 1 și 2 pagini.

Capitolul ar trebui sa conțină (nu se rezumă neapărat la):

- un rezumat al contribuțiilor voastre
- analiză critică a rezultatelor obținute
- descriere a posibilelor dezvoltări și îmbunătățiri ulterioare

Bibliografie

- [1] A. Breitenfeld and C. Muller-Birn, “A state-of-the-art review of semantic annotation tools,” <http://dx.doi.org/10.17169/refubium-25139>, 2017.
- [2] M. Everingham, L. Gool, C. K. Williams, J. Winn, and A. Zisserman, “The pascal visual object classes (voc) challenge,” *Int. J. Comput. Vision*, vol. 88, no. 2, p. 303–338, Jun. 2010. [Online]. Available: <https://doi.org/10.1007/s11263-009-0275-4>
- [3] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays, P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár, “Microsoft coco: Common objects in context,” 2015. [Online]. Available: <https://arxiv.org/abs/1405.0312>
- [4] A. Torralba and A. A. Efros, “Unbiased look at dataset bias,” in *CVPR 2011*, 2011, pp. 1521–1528.
- [5] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” 2015. [Online]. Available: <https://arxiv.org/abs/1505.04597>
- [6] B. Hariharan, P. Arbeláez, R. Girshick, and J. Malik, “Simultaneous detection and segmentation,” 2014. [Online]. Available: <https://arxiv.org/abs/1407.1808>
- [7] A. Kirillov, K. He, R. Girshick, C. Rother, and P. Dollár, “Panoptic segmentation,” 2019. [Online]. Available: <https://arxiv.org/abs/1801.00868>
- [8] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, “Masked-attention mask transformer for universal image segmentation,” 2022. [Online]. Available: <https://arxiv.org/abs/2112.01527>
- [9] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.00020>
- [10] F. Liang, B. Wu, X. Dai, K. Li, Y. Zhao, H. Zhang, P. Zhang, P. Vajda, and D. Marculescu, “Open-vocabulary semantic segmentation with mask-adapted clip,” 2023. [Online]. Available: <https://arxiv.org/abs/2210.04150>
- [11] A. Wang, L. Liu, H. Chen, Z. Lin, J. Han, and G. Ding, “Yoloe: Real-time seeing anything,” 2025. [Online]. Available: <https://arxiv.org/abs/2503.07465>
- [12] H. Liu, C. Li, Q. Wu, and Y. J. Lee, “Visual instruction tuning,” 2023. [Online]. Available: <https://arxiv.org/abs/2304.08485>
- [13] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, “Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter,” 2020. [Online]. Available: <https://arxiv.org/abs/1910.01108>

-
- [14] B. Settles, “Active learning literature survey,” University of Wisconsin–Madison, Computer Sciences Technical Report 1648, 2009.
 - [15] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” *International Journal of Computer Vision*, vol. 128, no. 2, p. 336–359, Oct. 2019. [Online]. Available: <http://dx.doi.org/10.1007/s11263-019-01228-7>
 - [16] L. Castrejon, K. Kundu, R. Urtasun, and S. Fidler, “Annotating object instances with a polygon-rnn,” 2017. [Online]. Available: <https://arxiv.org/abs/1704.05548>
 - [17] K.-K. Maninis, S. Caelles, J. Pont-Tuset, and L. V. Gool, “Deep extreme cut: From extreme points to object segmentation,” 2018. [Online]. Available: <https://arxiv.org/abs/1711.09081>
 - [18] B. Chen, H. Ling, X. Zeng, G. Jun, Z. Xu, and S. Fidler, “Scribblebox: Interactive annotation framework for video object segmentation,” 2020. [Online]. Available: <https://arxiv.org/abs/2008.09721>
 - [19] A. Torralba, B. C. Russell, and J. Yuen, “Labelme: Online image annotation and applications,” *Proceedings of the IEEE*, vol. 98, no. 8, pp. 1467–1484, 2010.
 - [20] C. contributors, “Cvat: Computer vision annotation tool,” GitHub repository, 2025. [Online]. Available: <https://github.com/cvat-ai/cvat>
 - [21] C. Sun, D. Sun, A. Ng, W. Cai, and B. Cho, “Real differences between ot and crdt under a general transformation framework for consistency maintenance in co-editors,” *Proceedings of the ACM on Human-Computer Interaction*, vol. 4, no. GROUP, pp. 1–26, 2020. [Online]. Available: <https://doi.org/10.1145/3375186>
 - [22] “Stomp protocol specification, version 1.2,” STOMP Project. [Online]. Available: <https://stomp.github.io/stomp-specification-1.2.html>
 - [23] J. James, “Counting on consensus: Selecting the right inter-annotator agreement metric for nlp annotation and evaluation,” 2026. [Online]. Available: <https://arxiv.org/abs/2603.06865>
 - [24] L. Moreau and P. Missier, “Prov-dm: The prov data model,” W3C Recommendation, 2013. [Online]. Available: <https://www.w3.org/TR/prov-dm/>
 - [25] “Postgresql documentation,” PostgreSQL Global Development Group. [Online]. Available: <https://www.postgresql.org/docs/>
 - [26] Y. Kang, J. Hauswald, C. Gao, A. Rovinski, T. Mudge, J. Mars, and L. Tang, “Neurosurgeon: Collaborative intelligence between the cloud and mobile edge.” New York, NY, USA: Association for Computing Machinery, 2017. [Online]. Available: <https://doi.org/10.1145/3037697.3037698>
 - [27] X. Wang, H. Zhang, M. Yang, X. Wu, and P. Cheng, “Privacy-preserving collaborative learning: A scheme providing heterogeneous protection,” *IEEE Internet of Things Journal*, vol. 11, no. 2, pp. 1840–1853, 2024.

Anexa A. Secțiuni relevante din cod

```
/** Maps are easy to use in Scala. */
object Maps {
  val colors = Map("red" -> 0xFF0000,
                   "turquoise" -> 0x00FFFF,
                   "black" -> 0x000000,
                   "orange" -> 0xFF8040,
                   "brown" -> 0x804000)

  def main(args: Array[String]) {
    for (name <- args) println(
      colors.get(name) match {
        case Some(code) =>
          name + " has code: " + code
        case None =>
          "Unknown color: " + name
      }
    )
  }
}
```

Anexa B. Alte informații relevante (demonstrații etc.)

Se va elimina dacă nu există

Anexa C. Lucrări publicate (dacă există)

Se va elimina dacă nu există