



UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

TOOL COLABORATIV SEMI-AUTOMAT DE ADNOTARE

LUCRARE DE LICENȚĂ

Absolvent: **Victor-Andrei GRIGORAȘ**

Coordonator **SL. Dr. Ing. Mircea-Paul MUREȘAN**
științific:

2026



UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL CALCULATOARE

DECAN,
Prof. dr. ing. Vlad MUREȘAN

DIRECTOR DEPARTAMENT,
Prof. dr. ing. Rodica POTOLEA

Absolvent: **Victor-Andrei GRIGORAȘ**

TOOL COLABORATIV SEMI-AUTOMAT DE ADNOTARE

1. **Enunțul temei:** *Dezvoltarea unui instrument de adnotare vizuală semi-automat, asistat de Inteligență Artificială, cu capabilități de lucru colaborativ, pentru eficientizarea procesului de etichetare și reducerea timpului și a efortului.*
2. **Conținutul lucrării:** *Pagina de prezentare, introducere, obiectivele lucrării, studiu bibliografic, analiză și fundamentare teoretică, proiectare de detaliu și implementare, testare și validare, manual de instalare și utilizare, concluzii, bibliografie și anexe.*
3. **Locul documentării:** Universitatea Tehnică din Cluj-Napoca, Departamentul Calculatoare
4. **Consultanți:**
5. **Data emiterii temei:** 1 Octombrie 2025
6. **Data predării:** 10 Iulie 2026

Absolvent: _____

Coordonator științific: _____

**FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE**
DEPARTAMENTUL CALCULATOARE**Declarație pe propria răspundere privind
autenticitatea lucrării de licență**

Subsemnatul(a) _____, _____ legitimat(ă) cu

_____ seria _____ nr. _____
(conform copiei anexate prezentei declarații, copie sem-
nată și certificată "conform cu originalul"), autorul lucrării

elaborată în vederea susținerii examenului de finalizare a studiilor de licență la Facultatea de Automatică și Calculatoare, Programul de studiu _____ din cadrul Universității Tehnice din Cluj-Napoca, sesiunea _____ a anului universitar _____, declar pe proprie răspundere, că această lucrare este rezultatul propriei activități intelectuale, pe baza cercetărilor mele și pe baza informațiilor obținute din surse care au fost citate, în textul lucrării și în bibliografie.

Declar, că această lucrare nu conține porțiuni plagiate, iar sursele bibliografice au fost folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor.

Declar, de asemenea, că această lucrare nu a mai fost prezentată în fața unei alte comisii de examen de licență.

În cazul constatării ulterioare a unor declarații false, voi suporta sancțiunile administra- tive, respectiv, *anularea examenului de licență*. Sunt de acord ca, pe tot parcursul vieții, în cazul în care este necesar și se va dori verificarea autenticității lucrării mele să fiu identificat și verificat în baza datelor declarate de mine și conform copiei documentului de identitate menționat mai sus.

Data

Nume, Prenume

Semnătura

Instrucțiuni generale.

De citit înainte (această pagină se va elimina din versiunea finală):

1. Cele trei pagini anterioare (foaie de capăt, foaie sumar, declarație) se vor lista pe foi separate (nu față-verso), fiind incluse în lucrarea listată. Foaia de sumar (a doua) necesită semnătura absolventului, respectiv a coordonatorului. Pe declarație se trece data când se predă lucrarea la secretarii de comisie.
2. Pe foaia de capăt, se va trece corect titulatura cadrului didactic îndrumător, în engleză (consultați pagina de unde ați descărcat acest document pentru lista cadrelor didactice cu titlaturile lor).
3. Fiecare capitol începe pe pagină nouă.
4. Marginile paginilor nu se modifică.
5. Respectați restul instrucțiunilor din fiecare capitol.
6. Am inclus pachetul `hyperref` pentru a genera legături de navigare atât în document cât și la link-uri de web. Pentru listarea pe hârtie a fișierului pdf de comentarii linia care conține `%\hypersetup{hidelinks}` aflată în partea de început a fișierului principal `thesis_rom.tex`.

Cuprins

Capitolul 1	Introducere	1
1.1	Context și motivație	1
1.2	Domeniul și delimitarea temei	1
1.3	Soluția propusă și contribuții	2
1.4	Arhitectură colaborativă	2
Capitolul 2	Obiectivele proiectului	3
2.1	Introducere	3
2.2	Obiectivul general	3
2.3	Obiective principale	3
2.4	Obiective secundare	4
2.5	Cerințe funcționale și non-funcționale	5
2.5.1	Cerințe funcționale	5
2.5.2	Cerințe non-funcționale	5
Capitolul 3	Studiu bibliografic	6
Capitolul 4	Analiză și fundamentare teoretică	13
4.1	Nume de secțiune	13
4.1.1	Nume de subsecțiune	13
Capitolul 5	Proiectare de detaliu și implementare	15
Capitolul 6	Testare și validare	16
Capitolul 7	Manual de instalare și utilizare	17
Capitolul 8	Concluzii	18
	Bibliografie	19
Anexa A	Secțiuni relevante din cod	21
Anexa B	Alte informații relevante (demonstrații etc.)	22
Anexa C	Lucrări publicate (dacă există)	23

Capitolul 1. Introducere

1.1. Context și motivație

În ultimii ani, aplicațiile de viziune artificială au devenit uzuale în industrie și cercetare, iar calitatea lor depinde direct de seturile de date etichetate. Procesul de adnotare vizuală implică trasarea manuală a obiectelor în imagini, fie prin dreptunghiuri de încadrare, fie prin poligoane sau măști. Pentru seturi mari de date, această muncă este consumatoare de timp și necesită atenție constantă pentru a menține consistența între adnotări. În practică, multe proiecte întârzie sau cresc în cost tocmai din cauza efortului de etichetare.

Motivația lucrării pornește din nevoia de a reduce timpul și efortul necesare adnotării, fără a pierde controlul uman asupra rezultatului final. O abordare semi-automată, în care un model de inteligență artificială propune contururi sau măști, poate accelera semnificativ procesul. Utilizatorul rămâne totuși responsabil de validare și corectare, ceea ce păstrează calitatea datelor. În plus, exportul adnotărilor în formate standard ajută la integrarea rapidă a datelor în fluxuri de antrenare.

Un alt aspect important este colaborarea între mai mulți utilizatori. În proiectele reale, adnotarea se face de obicei în echipă, iar lipsa sincronizării duce la duplicarea muncii și la inconsistențe. Printr-un mecanism de lucru colaborativ, cu actualizări în timp real și gestionarea sesiunilor, echipa poate lucra pe același proiect în mod coordonat. Astfel, se obține un proces mai rapid, mai controlat și mai ușor de urmărit.

1.2. Domeniul și delimitarea temei

Lucrarea se încadrează în domeniul adnotării vizuale pentru date de tip imagine, cu accent pe segmentare și detecție de obiecte. Sunt vizate adnotări realizate prin dreptunghiuri, poligoane și măști, deoarece acestea acoperă cele mai folosite reprezentări în seturile de date moderne.

Domeniul ales include și administrarea etichetelor și a adnotărilor, astfel încât acestea să poată fi organizate și verificate ușor.

Datele rezultate sunt salvate într-un format intern și pot fi exportate în formate standard, precum COCO (Common Objects in Context) și YOLO (You Only Look Once). Astfel, seturile de date pot fi folosite ușor în fluxuri de antrenare, fără pași suplimentari de conversie. Structura de export este gândită pentru a păstra separarea între tipurile de adnotări și pentru a face reutilizarea cât mai simplă.

Tema este delimitată la un instrument desktop de adnotare, care integrează metode semi-automate prin apelarea unor modele externe. Modelul nu este antrenat în cadrul lucrării, ci este folosit ca suport pentru propunerea conturilor. Pentru segmentare asistată este folosit un model de tip Mask2Former, iar pentru detecție și segmentare completă se folosește un model de tip YOLOE.

Nu sunt urmărite subiecte precum optimizarea arhitecturilor de rețele neuronale, compararea extensivă a modelelor sau dezvoltarea unui serviciu cloud pentru adnotare. Accentul este pe realizarea unui instrument practic, ușor de folosit, local, care reduce efortul de etichetare și permite colaborarea eficientă între membri ai aceleiași echipe.

1.3. Soluția propusă și contribuții

Soluția propusă este o aplicație desktop dezvoltată în PyQt6, care oferă un flux de lucru complet pentru adnotarea imaginilor. Utilizatorul poate deschide un folder de imagini, alege rapid fișierele din listă și edita adnotările direct pe canvas. Interfața este organizată în panouri funcționale, astfel încât instrumentele de adnotare, lista de elemente și proprietățile acestora să fie accesibile fără a întrerupe procesul de lucru.

Canvasul este componenta centrală a interfeței. Acesta permite zoom și pan, desenarea de dreptunghiuri, poligoane sau măști, precum și selecția și modificarea elementelor existente. În plus, sunt disponibile ajustări vizuale ale imaginii pentru a crește claritatea în zonele dificil de adnotat. Acest mod de lucru ajută la păstrarea preciziei și reduce efortul în sarcinile repetitive.

Gestionarea adnotărilor se face printr-un manager central, care păstrează toate elementele asociate imaginii curente și oferă operații de adăugare, modificare sau ștergere. Managerul emite notificări către interfață atunci când apar schimbări, ceea ce asigură sincronizarea dintre starea internă și elementele afișate. Fiecare adnotare are un identificator propriu, fapt util pentru editare, export și colaborare.

Aplicația include facilități de tip *quality of life*, menite să reducă erorile și timpul pierdut. La închiderea aplicației sau la schimbarea imaginii, utilizatorul este întrebat dacă dorește să salveze modificările. În plus, aplicația include chat în timp real și suport de tip chatbot local pentru asistență.

Componenta de inteligență artificială este integrată prin AutoSeg și AutoMask, care rulează modele externe ca subprocese asincrone. Rezultatele sunt transformate în adnotări editabile, iar utilizatorul le poate corecta imediat. Astfel, aplicația combină propunerea automată cu controlul manual, obținând un echilibru între viteză și acuratețe.

Contribuțiile principale constau în integrarea unui flux complet de adnotare cu suport pentru segmentare semi-automată, organizarea clară a interfeței și mecanismele de sincronizare în colaborare. Rezultatul este un instrument practic, adaptat nevoilor de etichetare din proiecte reale.

1.4. Arhitectură colaborativă

Backend-ul aplicației este separat pe servicii dedicate pentru autentificare, chat și colaborare pe adnotări. Un reverse proxy direcționează cererile către serviciul corespunzător, iar mesageria facilitează schimbul de informații între module. Această separare permite dezvoltarea și testarea componentelor în mod independent, păstrând totuși un flux unitar pentru utilizator.

Sincronizarea se bazează pe două tipuri de comunicație. Prin REST, clientul listează sesiunile, obține un snapshot al stării curente și poate încărca sau descărca imagini temporare. Prin WebSocket, clienții primesc evenimente în timp real, precum crearea, actualizarea sau ștergerea adnotărilor. Când o imagine este actualizată într-o sesiune, ceilalți utilizatori primesc un eveniment de tip „image available” și sincronizează automat datele.

Modelul de colaborare este centrat pe sesiuni, fiecare sesiune având o stare curentă și o versiune a adnotărilor. Astfel, modificările sunt propagate rapid, iar utilizatorii văd același conținut fără conflicte majore. Autentificarea prin JWT (JSON Web Token) limitează accesul doar la utilizatorii autorizați, iar token-ul este salvat local pentru a evita relogarea repetată.

Capitolul 2. Obiectivele proiectului

2.1. Introducere

Acest capitol prezintă obiectivele proiectului. Ele sunt legate direct de problema adnotării vizuale și descriu ce se urmărește prin realizarea aplicației. Structura include obiectivul general, obiectivele principale și secundare, precum și cerințele funcționale și non-funcționale.

2.2. Obiectivul general

În mod obișnuit, adnotarea datelor vizuale este o muncă manuală, costisitoare și lentă, iar rezultatele pot fi influențate de oboseală și erori umane. Acest context creează nevoia unei soluții care să accelereze procesul, fără a pierde controlul asupra calității.

Obiectivul general al proiectului este dezvoltarea unei aplicații desktop de adnotare vizuală, semi-automată și colaborativă, care reduce timpul de etichetare și păstrează controlul utilizatorului asupra rezultatului final. Aplicația trebuie să ofere un flux de lucru complet, de la încărcarea imaginilor și navigarea rapidă între ele, până la editarea adnotărilor și exportul în formate standard. În mod explicit, trebuie să suporte adnotări de tip bounding box (dreptunghi), poligon și mască (image segmentation), pentru a acoperi scenariile uzuale de detecție și segmentare.

Gestionarea adnotărilor trebuie să fie clară și previzibilă, cu posibilitatea de selecție, editare și ștergere, astfel încât utilizatorul să poată corecta rapid erorile. Rezultatele trebuie să poată fi salvate și exportate în formate standard, pentru a fi folosite ușor în antrenarea modelelor. Prin integrarea unor modele externe pentru propuneri de segmentare și prin suportul pentru colaborare securizată între utilizatori, soluția urmărește să crească eficiența fără a compromite calitatea datelor.

2.3. Obiective principale

Obiectivele principale urmăresc să definească funcționalitățile cheie ale aplicației și modul în care acestea răspund cerințelor de adnotare. Fiecare obiectiv este formulat astfel încât să poată fi implementat și verificat concret.

- **Interfață de adnotare completă.** Realizarea unui canvas interactiv cu zoom și pan, care permite desenarea de adnotări de tip bounding box, poligon și mască. Interfața trebuie să susțină navigarea rapidă între imagini și un control vizual clar.
- **Gestionarea coerentă a adnotărilor.** Păstrarea unei structuri clare pentru etichete și elemente, cu identificatori unici, listare și operații de editare sau ștergere. Această structură reduce erorile și facilitează modificările ulterioare.
- **Export standardizat al datelor.** Oferirea de export în formatele COCO și YOLO, cu organizare predictibilă a fișierelor. Astfel, dataset-urile pot fi folosite direct în antrenare, fără conversii suplimentare.
- **Integrare AI semi-automată.** Folosirea AutoSeg și AutoMask pentru a genera propuneri de segmentare care pot fi corectate imediat de utilizator. Scopul este accelerarea procesului fără a compromite calitatea adnotărilor.

- **Modularizarea execuției AI.** Rularea modelelor ca aplicații separate, prin procese dedicate, pentru a izola erorile și a permite actualizări independente. Această abordare crește stabilitatea și flexibilitatea sistemului.
- **Colaborare în timp real.** Realizarea unui server separat pentru colaborare, cu suport de conectare și sesiuni comune, apoi sincronizare a evenimentelor de tip create, update și delete. Actualizarea imaginii între utilizatori se face prin REST și WebSocket pentru a evita duplicarea muncii.
- **Comunicare între utilizatori.** Oferirea unei interfețe de chat care permite schimbul de mesaje între utilizatori în timpul sesiunilor de lucru.
- **Securitate și acces controlat.** Autentificarea pe bază de JWT și păstrarea locală a token-ului pentru o experiență de lucru fluidă. Accesul la sesiuni și date trebuie să fie controlat și verificabil.
- **Evaluarea și selecția modelelor AI externe.** Testarea Mask2Former și YOLOE pe imagini de referință, cu măsurarea timpului de procesare și a calității rezultatelor. Alegerea finală trebuie justificată pe baza acestor rezultate.
- **Impachetarea și integrarea backend-urilor de inferență.** Folosirea unui script care facilitează build-uirea executabilului, pentru un export simplu și repetabil. Integrarea trebuie să permită conectarea ușoară a backend-urilor la aplicație.

2.4. Obiective secundare

Obiectivele secundare completează funcționalitățile principale prin îmbunătățirea experienței de utilizare și prin validări suplimentare ale componentelor AI și de colaborare.

- **Benchmarking pentru modele alternative.** Analizarea unor modele open-vocabulary (YOLO-World, LLMDet, SAM2) pentru a observa potențialul de generalizare și a justifica alegerea finală.
- **Validarea suportului local de tip VLM/LLM.** Compararea mai multor modele rulate local (Ollama) pentru a susține componenta de chatbot și a stabili un compromis calitate-viteză. Chatbotul are rolul de a ajuta utilizatorul cu întrebări și de a oferi sugestii pentru remedieri ale erorilor întâlnite.
- **Experiență de utilizare și prevenirea erorilor.** Confirmare la schimbarea imaginii și la închidere pentru a evita pierderea adnotărilor.
- **Persistența setărilor vizuale.** Salvarea preferințelor (grosime contur, dimensiune font, opacitate mască) între sesiuni.
- **Îmbunătățirea vizuală a imaginii.** Ajustări de luminozitate, contrast și gamma fără a altera datele originale.
- **Încărcare inteligentă a adnotărilor.** Asocierea automată a fișierelor JSON cu imaginea corespunzătoare.
- **Optimizarea serializării măștilor.** Compresie și reducerea volumului de date pentru fișiere mari.
- **Reducerea traficului în colaborare.** Împărțirea actualizărilor mari (ex. măști) în batch-uri și trimiterea lor prin WebSocket, pentru a evita închiderea prematură a conexiunii. Se aplică și deduplicarea evenimentelor.
- **Crosshair și ghidaj vizual.** Indicatori pentru precizie în adnotare și selectare.

2.5. Cerințe funcționale și non-funcționale

Pentru a susține obiectivele prezentate, proiectul are un set de cerințe funcționale și non-funcționale, sintetizate în tabelele de mai jos.

2.5.1. Cerințe funcționale

Cerință	Descriere scurtă
Încărcare și navigare imagini	Deschidere folder, listare rapidă și comutare între imagini.
Canvas de adnotare	Zoom, pan și trasare de bounding box, poligon și mască.
Editare adnotări	Selectare, modificare, ștergere, etichete și culori ușor de gestionat.
Import/Export	Salvare JSON și export COCO/YOLO cu structură predictibilă.
AI semi-automată	AutoSeg/AutoMask pentru propuneri rapide, corectabile imediat.
Modularizare AI	Rulare modele ca procese separate pentru izolare și actualizări.
Colaborare	Sesiuni, sincronizare create/update/delete prin REST și WebSocket.
Autentificare	Acces controlat cu JWT și token salvat local.
Comunicare	Chat între utilizatori și chatbot local pentru întrebări și erori.
Personalizare	Setări vizuale persistente și confirmare la închidere/schimbare.

2.5.2. Cerințe non-funcționale

Cerință	Descriere scurtă
Usabilitate	Interfață clară, operații frecvente accesibile rapid.
Performanță	Interfață responsivă în timpul procesării AI (asincron).
Fiabilitate	Validări pentru căi inexistente și mesaje clare de eroare.
Securitate	Protecția sesiunilor și a datelor prin token.
Integritate date	Exporturi consistente, fără pierderi de informație.
Scalabilitate	Mai mulți utilizatori pot lucra în aceeași sesiune.
Mentenabilitate	Arhitectură modulară pentru întreținere și extindere.
Extensibilitate	Adăugare de modele și formate noi fără refactor major.
Portabilitate	Rulare locală pe Windows cu configurare minimă.

Capitolul 3. Studiu bibliografic

Pentru realizarea unui instrument local de adnotare, documentarea bibliografică a fost organizată pe topicuri relevante domeniului, rezumate și corelate cu obiectivele proiectului.

În raportul tehnic din 2017 al lui Breitenfeld și Muller-Birn se prezintă o trecere în revistă a instrumentelor de adnotare semantică folosite în contexte de cercetare, cu accent pe legarea conținutului la vocabulari controlate și baze de cunoștințe [1]. Autorii compară uneltele după publicul țintă, formatele suportate, sursele de cunoștințe (de tip RDF/SKOS), modul de interacțiune și contextul de rulare (web, desktop sau integrare în infrastructuri de cercetare). Analiza evidențiază diferențe între unelte orientate spre utilizatori tehnici și cele care încearcă să includă experți de domeniu prin interfețe mai prietenoase.

Concluzia principală este că multe instrumente sunt orientate către utilizatori tehnici, iar suportul pentru colaborare și provenance rămâne limitat, ceea ce îngreunează adopția în echipe interdisciplinare. Deși lucrarea tratează adnotarea semantică (nu vizuală), observațiile despre uzabilitate, colaborare și trasabilitate sunt relevante pentru proiectul de față, unde aceleași nevoi apar în procesul de etichetare a imaginilor. Din această perspectivă, studiul oferă un context util pentru alegerea unui flux de lucru local, simplificat și orientat pe utilizator.

Pentru sincronizarea colaborativă, Sun et al. analizează diferențele reale dintre OT (Operational Transformation) și CRDT (Commutative Replicated Data Type) într-un cadru unificat de transformare [2]. Autorii separă starea vizibilă de utilizator (external state) de structurile interne de sincronizare, comparând modul în care fiecare paradigmă gestionează operațiile concurente. Ei arată că și CRDT implică transformări indirecte și costuri suplimentare, ceea ce poate afecta performanța în sisteme interactive. Concluziile sugerează că, pentru aplicații cu server central și colaborare în timp real, un model operațional bazat pe evenimente poate fi mai predictibil și mai eficient decât un CRDT complex. Pentru un instrument de adnotare colaborativă, această perspectivă susține propagarea operațiilor (de tip create/update/delete) în locul trimerii stării complete.

Arhitecturile event-driven facilitează colaborarea în timp real prin transmiterea asincronă a evenimentelor peste conexiuni persistente, iar STOMP (Simple Text Oriented Messaging Protocol) oferă un protocol text-based simplu pentru publicare/abonare peste TCP sau WebSocket [3]. STOMP definește frame-uri standard (CONNECT, SEND, SUBSCRIBE, MESSAGE, ACK/NACK, DISCONNECT) și separă clar canalul de transport de logica de rutare, ceea ce îl face potrivit pentru sincronizarea modificărilor pe canvas, notificări și comentarii. Pentru proiect, acest model susține broadcast instant al schimbărilor, locking/editing de obiecte și interoperabilitate între frontend și backend.

Lucrarea despre Microsoft COCO introduce un set de date de referință pentru detecție, segmentare și descriere de imagini în contexte cotidiene, punând accent pe scene complexe cu obiecte multiple [4]. Dataset-ul include sute de mii de imagini și peste două milioane de instanțe etichetate, acoperind zeci de clase obiect, grupate în supercategorii. Anotările sunt detaliate (instance segmentation, bounding box-uri și capturi textuale), iar evaluarea folosește metrici bazate pe precizie la mai multe praguri IoU (Intersection

over Union), pentru a reflecta mai realist calitatea localizării. COCO a devenit un reper pentru comparații între modele și a standardizat modul de evaluare în sarcini de adnotare și segmentare.

PASCAL VOC a fost creat pentru a standardiza evaluarea în recunoașterea obiectelor, folosind imagini realiste, clase bine definite și proceduri clare de adnotare și scoring [5]. Setul introduce sarcini de clasificare, detecție și segmentare, cu evaluare bazată pe Average Precision și praguri IoU (de exemplu 0.5 pentru detecție), plus etichete auxiliare precum „difficult” și „truncated”. Studiul evidențiază limitele detectorilor de atunci la localizare fină (AP scade puternic la praguri IoU mai stricte) și costul mare al adnotării, mai ales pentru segmentare pixel-level.

Relevanța pentru proiect este dublă: oferă un benchmark realist pentru testarea motorului de adnotare și furnizează un cadru clar de metrici și ghiduri de adnotare. Pentru un instrument colaborativ, principiile VOC susțin introducerea unor reguli explicite de trasare a box-urilor, excluderea obiectelor „difficult” din evaluarea inițială și calculul automat de AP/IoU pentru a compara calitatea adnotărilor umane sau semi-automate.

Pentru versionarea și trasabilitatea adnotărilor, standardul W3C PROV-DM oferă un model formal pentru a descrie cum sunt generate și modificate entitățile digitale [6]. Modelul introduce concepte precum entitate, activitate și agent, precum și relații de tipul `wasGeneratedBy` și `wasDerivedFrom`, care permit reconstruirea istoricului unei adnotări. În contextul adnotării colaborative, aceste mecanisme susțin auditarea modificărilor, reproducibilitatea și controlul calității, mai ales atunci când adnotările sunt create atât de utilizatori, cât și de modele automate.

În practică, sistemele moderne de adnotare folosesc o separare clară între meta-datele structurate (proiecte, task-uri, etichete, istoricul modificărilor) și media nestructurată (imagini, videoclipuri). Metadatele sunt potrivite pentru un RDBMS precum PostgreSQL, care oferă tranzacții ACID, control concurent și indexare eficientă, în timp ce fișierele media sunt stocate în sisteme de fișiere sau object storage și sunt referențiate prin chei în baza de date [7]. În proiect, PostgreSQL este folosit în mod limitat pentru autentificare, însă rămâne o opțiune optimă la nivel general și pentru extinderi viitoare care vor necesita organizarea metadatelor.

Calitatea adnotărilor este un factor critic pentru performanța modelelor, iar sistemele moderne folosesc mecanisme de asigurare a calității precum acordul între adnotatori, etichetarea prin consens, fluxuri de review și audituri periodice. Aceste practici reduc erorile umane și cresc consistența, mai ales în domenii sensibile, unde deciziile automate pot avea impact ridicat. Un alt aspect important este bias-ul seturilor de date, care poate distorsiona evaluările și generalizarea în practică.

În lucrarea „Unbiased Look at Dataset Bias”, Torralba și Efros analizează bias-ul seturilor de date din recunoașterea obiectelor și arată că modelele învață adesea semnături specifice dataset-ului, nu concepte vizuale generale [8]. Ei compară mai multe colecții (PASCAL VOC, ImageNet, LabelMe, SUN09, Caltech101, MSRC) și folosesc experimente de tip „Name That Dataset” și teste de generalizare între dataset-uri. Rezultatele indică faptul că acuratețea scade semnificativ atunci când antrenarea și testarea se fac pe surse diferite, iar bias-ul de selecție, captură și negative set afectează direct robustețea modelelor.

Studiul este pre-deep learning și se bazează pe HOG/BoW (Histogram of Oriented Gradients/Bag of Words) cu SVM (Support Vector Machine), ceea ce limitează comparațiile cu modele moderne, dar concluziile despre bias rămân relevante. Pentru un instrument de adnotare colaborativă, lucrarea susține importanța fluxurilor de QA

(Quality Assurance), a consensului între adnotatori și a controlului asupra distribuției datelor și a exemplelor negative.

Lucrarea „Counting on Consensus” oferă un ghid pentru alegerea metricilor de acord între adnotatori (IAA), subliniind că procentul brut de acord este înșelător, mai ales în clase dezechilibrate, și recomandă metrici corectate pentru hazard precum Kappa sau Alpha [9]. Pentru etichete continue/ordonate sunt relevante Kappa ponderată sau ICC, iar pentru adnotări structurate sunt utile măsuri de suprapunere (F1/Dice) și metrici de frontieră. Deși focusul este pe NLP, principiile se transferă la adnotarea de imagini: sistemul poate calcula IAA pe etichete și pe măști, poate semnaliza cazurile ambigue și poate impune raportarea intervalelor de încredere. Pentru proiect, aceasta sprijină un pipeline de QA bazat pe consistență, fără a confunda fiabilitatea cu validitatea.

Tehnicile de vizualizare și interpretare precum Grad-CAM folosesc gradientul din ultimul strat convoluțional pentru a produce o hartă de localizare a regiunilor discriminative [10]. În practică, această hartă poate fi suprapusă peste imagine pentru a evidenția zonele relevante pentru decizia modelului.

Pentru proiect, aceste tehnici sunt utile ca mecanisme de QA și transparență: pot arăta rapid de ce modelul a sugerat o etichetă sau o mască, pot evidenția erori de focalizare (ex. modelul urmărește fundalul) și pot sprijini detectarea bias-ului din date. Într-un UI colaborativ, afișarea heatmap-urilor ca overlay ajută la validarea rapidă a sugestiilor și la corectarea interactivă, reducând timpul de revizie fără a sacrifica acuratețea.

În raportul tehnic despre învățarea activă, Settles descrie cum un model poate obține performanțe ridicate cu mai puține etichete dacă selectează instanțele cele mai informative pentru adnotare [11]. Lucrarea acoperă scenarii precum sinteza interogărilor, eșantionarea din flux și eșantionarea dintr-un rezervor, precum și strategii de interogare (incertitudine, comitet, reducerea erorii așteptate). În practică, învățarea activă reduce efortul de etichetare, dar introduce provocări legate de costuri variabile, oracole zgometoase și bias indus de selecție.

Pentru un instrument colaborativ de adnotare, aceste idei sunt utile deoarece permit prioritizarea imaginilor sau a regiunilor care aduc maxim de informație, evitând munca redundantă. Abordări precum batch-mode active learning pot distribui eficient sarcinile către mai mulți adnotatori, iar mecanismele de reetichetare pot compensa erorile umane. Totuși, costul computațional al selecției și dependența de modelul curent rămân limitări care trebuie luate în calcul.

În fluxurile human-in-the-loop pentru segmentare, modelul propune contururi, iar utilizatorul corectează și validează rezultatele, reducând timpul de adnotare fără a pierde controlul asupra calității. Aceste sisteme sunt relevante în domenii cu cerințe ridicate de precizie, unde verificarea umană rămâne esențială.

Polygon-RNN propune adnotarea instanțelor ca poligoane generate secvențial de un RNN (Recurrent Neural Network) peste caracteristici extrase de un CNN (Convolutional Neural Network), iar utilizatorul poate corecta vârfurile în timpul generării [12]. Modelul învață să prezică vârfuri pe o grilă discretizată și se oprește la un token de final, ceea ce transformă desenarea completă într-un proces de ajustare. Autorii raportează accelerări semnificative față de adnotarea manuală, menținând un acord ridicat în termeni de IoU.

Pentru proiect, această abordare susține ideea de asistență IA (Inteligența Artificială) cu feedback uman, unde interfața trebuie să permită corecturi rapide și să integreze imediat rezultatul în forma finală. Metoda evidențiază că un workflow mixt poate reduce efortul, dar depinde de un design UI (User Interface) clar și de modele suficient de stabile

pentru a nu genera multe corecții.

ScribbleBox propune un flux în două etape pentru adnotare video: Curve-VOT urmărește obiectul printr-o curbă temporală cu câteva puncte de control, iar Scribble-VOS rafinează măștile pe baza scribble-urilor propagate cu un GCN [13]. Pe DAVIS2017, metoda atinge 88.92% J&F cu 9.1 click-uri per box track și corecții pe doar 4 cadre, iar autorii raportează și latențe detaliate: propagarea măștilor la 512px ajunge la 295 ms/cadru, la 256px 152 ms, iar cu cache 82 ms; propagarea scribble-urilor este 15–28 ms, iar curve fitting și interacțiunea box sunt sub 15 ms.

Limitarea principală este dependența de calitatea trackingului inițial (obiecte mici sau mișcări imprevizibile necesită mai multe puncte de control). Pentru un instrument colaborativ, această structură permite împărțirea muncii (box-uri brute vs. rafinare), QA rapid prin scribble-uri și impune UI asincronă cu indicatori de progres, cache persistent și mod rapid/precis pentru a ascunde latențele mari, mai ales în regim multi-utilizator sau pe hardware limitat.

Deep Extreme Cut (DEXTR) reduce efortul de adnotare prin generarea unei măști precise din doar patru puncte extreme (sus, jos, stânga, dreapta), codate ca hărți Gaus-siene și oferite ca intrare suplimentară [14]. Astfel, utilizatorul nu mai trasează poligoane, ci indică rapid limitele obiectului, iar modelul produce o mască inițială de calitate. Limitarea apare la obiecte puternic ocluzionate sau cu forme neregulate, unde punctele extreme pot fi ambigue și necesită corecții.

Pentru proiect, DEXTR susține un flux „desenare, apoi corecție” în loc de „desenare completă”: masca inițială poate fi ajustată cu pensula sau prin re poziționarea punctelor extreme pentru re-inferență rapidă. Acest tip de post-editing scade timpul de QA și reduce bias-ul de oboseală, deoarece validarea se face pe câteva puncte cheie, nu pe sute de noduri.

Evoluția pattern-urilor UI/UX arată trecerea de la adnotarea manuală la interacțiune asistată. În LabelMe, utilizatorul editează direct poligoane (zoom, pan, adăugare/ștergere de noduri), oferind precizie dar cost ridicat pentru măști complexe [15]. În unele moderne precum ScribbleBox și CVAT, interacțiunea se reduce la indicii brute (casete sau scribbles), iar modelul produce rapid măști de calitate, cu feedback aproape instant [13, 16]. Modele eficiente, precum YOLOE, susțin acest feedback în regim open-vocabulary fără a introduce costuri mari la inferență [17].

La nivel de workflow colaborativ, CVAT structurează munca în proiecte, task-uri și job-uri, reducând conflictele și permițând paralelizarea adnotării [16]. Integrarea unui flux în două etape, similar cu ScribbleBox (box-uri brute urmate de rafinare), permite alocarea sarcinilor pe niveluri de expertiză: adnotatori juniori pot genera rapid box-uri, iar adnotatorii seniori pot rafina măștile dificile [13].

Pentru QA și managementul erorilor, pattern-urile de tip issues/comentarii (CVAT) și corecțiile non-distructive prin scribble-uri (ScribbleBox) reduc refacerile și accelerează verificarea [16, 13]. Practici precum consensus și honeypot-uri pot fi adăugate pentru a măsura consistența și a detecta erori sistematice, fără a întrerupe fluxul de lucru.

Scalabilitatea și performanța depind de menținerea latenței scăzute în UI. Optimizări structurale precum re-parametrizarea din YOLOE reduc costurile la rulare, iar partiționarea edge-cloud din Neurosurgeon permite rularea locală a straturilor ușoare și delegarea celor grele către backend [17, 18]. Pentru sarcini de segmentare mai costisitoare (ex. Mask2Former), această separare ajută la păstrarea interacțiunii fluide pentru mai mulți utilizatori concurenți [19].

Panoptic segmentation unifică segmentarea semantică și cea pe instanțe într-o

singură sarcină, astfel încât fiecare pixel primește o categorie semantică și, unde este cazul, un identificator de instanță. Kirillov et al. propun această formulare pentru a obține o înțelegere coerentă a scenei și introduc un criteriu de evaluare dedicat, Panoptic Quality (PQ), care combină calitatea segmentării și a recunoașterii [20]. Lucrarea a standardizat evaluarea prin adnotări panoptice și a influențat arhitecturi ulterioare (ex. Panoptic FPN, UPSNet, modele bazate pe transformere), fiind relevantă pentru proiect prin faptul că evidențiază necesitatea unor adnotări consistente și complete la nivel de imagine.

Instance segmentation combină detecția obiectelor cu segmentarea semantică, dar diferențiază instanțele distincte ale aceleiași clase. În lucrarea „Simultaneous Detection and Segmentation”, Hariharan et al. propun un cadru unificat care prezice simultan bounding box-uri și măști pentru fiecare obiect, folosind reprezentări pe regiuni și clasificare la nivel de instanță [21]. Metoda extinde detectoarele bazate pe regiuni prin integrarea unei predicții de mască, oferind o înțelegere mai fină a scenei decât segmentarea semantică clasică.

Relevanța pentru proiect este directă, deoarece adnotarea de instanțe cere atât localizarea obiectelor, cât și delimitarea precisă a conturilor. Lucrarea oferă un precedent conceptual pentru fluxuri de lucru care combină desenarea de bounding box-uri cu rafinarea măștilor, ceea ce susține nevoia de instrumente de adnotare flexibile și eficiente.

U-Net abordează segmentarea semantică în contexte cu puține date adnotate, propunând o arhitectură complet convoluțională în formă de U, cu cale de contractare și expansiune și conexiuni de tip skip pentru păstrarea detaliilor de rezoluție înaltă [22]. Modelul folosește o strategie overlap-tile pentru imagini mari, augmentare cu deformări elastice și o funcție de pierdere ponderată care accentuează separarea obiectelor adiacente. În evaluările ISBI, rezultatele au depășit metodele bazate pe ferestre glisante, raportând scoruri IoU ridicate chiar cu seturi de antrenare mici.

Limitările includ faptul că ieșirea este mai mică decât intrarea (convoluții fără umplutură), iar antrenarea necesită atenție la inițializare și la dimensiunea lotului. Pentru proiect, U-Net susține ideea de auto-segmentare rapidă în interfață, antrenare eficientă cu puține exemple și procesare pe dale pentru imagini de rezoluții mari.

CLIP (Contrastive Language-Image Pre-training) propune un mod de învățare a conceptelor vizuale din limbaj natural, antrenând simultan un encoder vizual și unul textual pe un set foarte mare de perechi imagine-text [23]. Obiectivul contrastiv maximizează similaritatea pentru perechi corecte și o minimizează pentru cele greșite, ceea ce permite transfer zero-shot: etichetele țintă sunt transformate în prompturi textuale (de tip „A photo of a {label}.“), iar imaginea este clasată prin potrivire cu descrierea cea mai probabilă. Rezultatele arată că CLIP poate concura cu modele complet supervizate pe ImageNet fără antrenare specifică pe acel dataset și este mai robust la schimbări de distribuție (schite, randări) decât modelele antrenate strict pe ImageNet. Encoderul vizual CLIP a devenit un fundament pentru modele open-vocabulary care adaptează reprezentările la regiuni mascate în segmentare [23, 24].

Lucrarea evidențiază și rolul prompt engineering: formulările contextuale și ensembling-ul de prompturi cresc performanța zero-shot. Limitările includ dificultăți în clasificare fine-grained, numărare și sarcini abstracte, precum și dependența de un volum masiv de date; în plus, bias-urile din datele web se pot reflecta în predicții, cu implicații etice și de confidențialitate [23]. Pentru proiect, CLIP este relevant ca fundament pentru interogări textuale flexibile în pre-adnotare și pentru că poate oferi sugestii rapide fără antrenare suplimentară, dar impune nevoia de verificare umană și de control al bias-urilor în fluxul

colaborativ.

DistilBERT propune distilarea cunoștințelor direct în faza de pre-antrenare, folosind un model profesor BERT și un student mai mic care imită distribuțiile de ieșire ale profesorului (soft labels) și alinierea embedding-urilor, printr-o funcție de pierdere compusă (distillation + language modeling + cosine) [25]. Rezultatul este un model cu 40% mai puțini parametri, cu inferență mai rapidă și performanță comparabilă (păstrează majoritatea capacității de înțelegere). În contextul chatbot-ului din platformă, DistilBERT este relevant pentru rularea locală sau pe edge a sarcinilor de NLP (completări, clasificări de intenții, sugestii de etichete), reducând latența și costurile, păstrând totodată posibilitatea de a apela modele mai mari doar când este nevoie.

Lucrarea despre segmentarea semantică open-vocabulary cu Mask-Adapted CLIP pornește de la limitarea seturilor închise și de la faptul că CLIP scade mult pe imagini mascate, din cauza domain gap-ului și a „zero tokens” introduși de fundal [24]. Autorii adaptează CLIP pe regiuni mascate și descrieri textuale, construind un set de date zgomotos din COCO Captions (extragere de substantive + aliniere automată a măștilor cu MaskFormer și CLIP) și propun Mask Prompt Tuning (MPT), care înlocuiește direct tokenii de fundal mascat cu tokeni de prompt învățabili, fie cu CLIP înghețat, fie cu fine-tuning complet.

OVSeg obține SOTA (State-of-the-Art) zero-shot (ex. mIoU 29.6 pe ADE20K-150, +8.5 față de OpenSeg, recorduri pe ADE20K-847 și Pascal Context-459), iar MPT singur aduce un câștig consistent cu puțini parametri antrenabili [24]. Limitările includ propuneri de măști influențate de clasele văzute, ambiguități lingvistice în evaluare, decalaj între clase văzute/nevăzute și faptul că modelele supervizate moderne rămân superioare. Pentru proiect, tehnica susține interogări textuale libere, pre-adnotare automată din metadate și adaptare eficientă în medii colaborative, cu un cost redus de memorie/GPU și nevoie de review pentru ambiguități lexicale.

YOLOE (modelul propus; extensie a familiei YOLO, You Only Look Once) oferă un model unificat, open-set (clase deschise) și real-time pentru detecție și segmentare, integrând prompturi textuale, vizuale și un mod prompt-free în aceeași arhitectură [17]. Pentru prompturi textuale, folosește RepRTA (Re-parameterizable Region-Text Alignment, aliniere regiune-text re-parametrizabilă): un bloc ușor de tip FFN (Feed-Forward Network) rafinează embedding-urile textuale la antrenare, apoi este re-parametrizat în capul de clasificare ca o convoluție 1×1 , fără cost suplimentar la inferență. Pentru prompturi vizuale, SAVPE (Semantic-Activated Visual Prompt Encoder, encoder de prompturi vizuale activat semantic) separă o ramură semantică (caracteristici agnostice de prompt) de o ramură de activare (ponderi specifice promptului), agregându-le eficient. În mod prompt-free, LRPC (Lazy Region-Prompt Contrast, contrast regiune-prompt „leneș”) învață un embedding care localizează toate obiectele, iar asocierea cu un vocabular extins se face doar pe ancorele relevante.

Rezultatele arată performanță open-set competitivă cu eficiență ridicată: reducere de 3x a costului de antrenare față de YOLO-World, câștiguri pe LVIS (Large Vocabulary Instance Segmentation) în zero-shot (fără adaptare pe setul de test) și viteză mai mare la inferență, plus transfer solid pe COCO față de YOLOv8 [17]. Limitările includ dependența de un vocabular static în modul prompt-free, de un encoder textual extern și necesitatea generării de pseudo-măști cu SAM (Segment Anything Model) pentru antrenarea segmentării. Pentru proiect, YOLOE este relevant prin suportul multimodal al adnotării (text sau indicii vizuale), posibilitatea unui mod de auto-etichetare prompt-free eficient și faptul că re-parametrizarea elimină costuri la rulare, facilitând deployment pe

servere ieftine sau pe client (edge) în fluxuri colaborative.

Mask2Former (modelul propus; Masked-attention Mask Transformer) abordează fragmentarea dintre segmentarea semantică, panoptică și de instanțe, propunând o arhitectură universală bazată pe mask classification, unde fiecare segment este reprezentat ca un object query [19]. Inovația este masked attention: în locul cross-attention global, interogările pot „vedea” doar regiunea prezisă la etapa anterioară, ceea ce accelerează convergența și reduce zgomotul de fundal. Decodorul folosește o strategie multi-scale eficientă (runde succesive pe 1/32, 1/16, 1/8), rulează masked attention înainte de self-attention și înlocuiește query-urile cu parametri antrenabili, astfel încât modelul propune intern regiuni validate direct de funcția de pierdere.

Pentru memorie, pierderile sunt calculate pe un eșantion de puncte informative, nu pe toți pixelii, reducând consumul VRAM la antrenare. Rezultatele raportează SOTA simultan pe COCO panoptic (PQ), COCO instance (AP) și ADE20K semantic (mIoU), cu convergență în 50 epoci față de sute de epoci la MaskFormer/DETR [19]. Limitările includ nevoia de antrenare separată per sarcină/dataset și performanța mai slabă pe obiecte foarte mici. Pentru proiect, Mask2Former este relevant prin unificarea infrastructurii de modele, posibilitatea de fine-tuning eficient pe seturi create colaborativ și generarea de contururi propuse cu focalizare locală, utilă pentru unelte de pre-select și corecție rapidă.

Neurosurgeon propune o schemă de „collaborative intelligence” între cloud și edge, unde un DNN este împărțit la un punct optim de separare între dispozitivul mobil și serverul cloud [18]. Modelul estimează timpul de execuție și energia pe fiecare strat atât local, cât și în cloud, apoi alege stratul L la care se transmite activarea către server, optimizând latența sau consumul energetic în funcție de lățimea de bandă și capabilitățile dispozitivului. Evaluările pe mai multe rețele arată că această împărțire reduce semnificativ latența sau energia față de rularea completă pe cloud sau complet locală.

Relevanța pentru proiect este directă: un instrument colaborativ de adnotare poate rula local straturile inițiale pentru feedback rapid (ex. propuneri brute), iar straturile costisitoare pot fi delegate către backend pentru rafinare. Astfel, se obține o experiență interactivă cu latență mică, în timp ce resursele serverului sunt folosite eficient, iar sistemul rămâne adaptiv la condițiile de rețea și la puterea dispozitivului utilizatorului [18].

Capitolul 4. Analiză și fundamentare teoretică

Împreună cu următoarele 2 capitole trebuie să reprezinte aproximativ 70% din total.

Scopul acestui capitol este de a explica principiile funcționale ale aplicației implementate. Aici se va descrie soluția propusă dintr-un punct de vedere teoretic - explicați și demonstrați proprietățile și valoarea teoretică:

- algoritmi utilizați sau propuși
- protocoale utilizate
- modele abstracte
- explicații/argumentări logice ale soluției alese
- structura logică și funcțională a aplicației.

NU SE FAC referiri la implementarea propriu-zisă.

NU SE PUN descrieri de tehnologii preluate cu copy-paste din alte surse sau lucruri care nu țin strict de proiectul propriu-zis (materiale de umplură).

4.1. Nume de secțiune

4.1.1. Nume de subsecțiune

Fiecare tabel introdus în lucrare este numerotat astfel: Tabel x.y, unde x reprezintă numărul capitolului, iar y numărul tabelului din capitol. Se lasă un rând liber între tabel și paragraful anterior, respectiv posterior (tabelul 4.1).

Tabela 4.1: Rezultate

Case	Method#1	Method#2	Method#3
1	50	837	970
2	47	877	230
3	31	25	415

Fiecare figură introdusă în text este citată (de ex: în figura x.y este prezentată ...) și numerotată. Numerotarea se face astfel Figura x.y unde x reprezintă numărul capitolului iar y numărul figurii în acel capitol. Numerotarea o face automat latex pe baza etichetei (`\label{}`).

Referirea unei figuri se face cu `\ref{}`. De exemplu, referința: figura 4.1.




Figura 4.1: Numele figurii

Capitolul 5. Proiectare de detaliu și implementare

Împreună cu capitolul **precedent** și cel **următor** trebuie să reprezinte aproximativ 70% din total.

Scopul acestui capitol este de a documenta aplicația dezvoltată în așa fel încât dezvoltarea și întreținerea ulterioară să fie posibile. Cititorul trebuie să identifice funcțiile principale ale aplicației din ceea ce este scris aici. Capitolul ar trebui să conțină (nu se rezumă neapărat la):

- schema generală a aplicației
- descrierea fiecărei componente implementate, la nivel de modul
- diagrame de clase, clase importante și metode ale claselor importante.
- diagrame de baze de date

Capitolul 6. Testare și validare

Împreună cu cele două capitole **precedente** trebuie să reprezinte aproximativ 70% din total.

Capitolul 7. Manual de instalare și utilizare

În secțiunea de Instalare trebuie să detaliați resursele software și hardware necesare pentru instalarea și rularea aplicației, precum și o descriere pas cu pas a procesului de instalare.

Instalarea aplicației trebuie să fie posibilă pe baza a ceea ce se scrie aici.

În acest capitol trebuie să descrieți cum se utilizează aplicația din punct de vedere al utilizatorului, fără a menționa aspecte tehnice interne.

Folosiți capturi ale ecranului și explicații pas cu pas ale interacțiunii.

Folosind acest manual, o persoană ar trebui să poată utiliza produsul vostru.

[Între 1 și 5 pagini.](#)

Capitolul 8. Concluzii

Între 1 și 2 pagini.

Capitolul ar trebui sa conțină (nu se rezumă neapărat la):

- un rezumat al contribuțiilor voastre
- analiză critică a rezultatelor obținute
- descriere a posibilelor dezvoltări și îmbunătățiri ulterioare

Bibliografie

- [1] A. Breitenfeld and C. Muller-Birn, “A state-of-the-art review of semantic annotation tools,” <http://dx.doi.org/10.17169/refubium-25139>, 2017.
- [2] C. Sun, D. Sun, A. Ng, W. Cai, and B. Cho, “Real differences between ot and crdt under a general transformation framework for consistency maintenance in co-editors,” *Proceedings of the ACM on Human-Computer Interaction*, vol. 4, no. GROUP, pp. 1–26, 2020. [Online]. Available: <https://doi.org/10.1145/3375186>
- [3] “Stomp protocol specification, version 1.2,” STOMP Project. [Online]. Available: <https://stomp.github.io/stomp-specification-1.2.html>
- [4] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays, P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár, “Microsoft coco: Common objects in context,” 2015. [Online]. Available: <https://arxiv.org/abs/1405.0312>
- [5] M. Everingham, L. Gool, C. K. Williams, J. Winn, and A. Zisserman, “The pascal visual object classes (voc) challenge,” *Int. J. Comput. Vision*, vol. 88, no. 2, p. 303–338, Jun. 2010. [Online]. Available: <https://doi.org/10.1007/s11263-009-0275-4>
- [6] L. Moreau and P. Missier, “Prov-dm: The prov data model,” W3C Recommendation, 2013. [Online]. Available: <https://www.w3.org/TR/prov-dm/>
- [7] “Postgresql documentation,” PostgreSQL Global Development Group. [Online]. Available: <https://www.postgresql.org/docs/>
- [8] A. Torralba and A. A. Efros, “Unbiased look at dataset bias,” in *CVPR 2011*, 2011, pp. 1521–1528.
- [9] J. James, “Counting on consensus: Selecting the right inter-annotator agreement metric for nlp annotation and evaluation,” 2026. [Online]. Available: <https://arxiv.org/abs/2603.06865>
- [10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-cam: Visual explanations from deep networks via gradient-based localization,” *International Journal of Computer Vision*, vol. 128, no. 2, p. 336–359, Oct. 2019. [Online]. Available: <http://dx.doi.org/10.1007/s11263-019-01228-7>
- [11] B. Settles, “Active learning literature survey,” University of Wisconsin–Madison, Computer Sciences Technical Report 1648, 2009.
- [12] L. Castrejon, K. Kundu, R. Urtasun, and S. Fidler, “Annotating object instances with a polygon-rnn,” 2017. [Online]. Available: <https://arxiv.org/abs/1704.05548>
- [13] B. Chen, H. Ling, X. Zeng, G. Jun, Z. Xu, and S. Fidler, “Scribblebox: Interactive annotation framework for video object segmentation,” 2020. [Online]. Available: <https://arxiv.org/abs/2008.09721>

-
- [14] K.-K. Maninis, S. Caelles, J. Pont-Tuset, and L. V. Gool, “Deep extreme cut: From extreme points to object segmentation,” 2018. [Online]. Available: <https://arxiv.org/abs/1711.09081>
 - [15] A. Torralba, B. C. Russell, and J. Yuen, “Labelme: Online image annotation and applications,” *Proceedings of the IEEE*, vol. 98, no. 8, pp. 1467–1484, 2010.
 - [16] C. contributors, “Cvat: Computer vision annotation tool,” GitHub repository, 2025. [Online]. Available: <https://github.com/cvat-ai/cvat>
 - [17] A. Wang, L. Liu, H. Chen, Z. Lin, J. Han, and G. Ding, “Yoloe: Real-time seeing anything,” 2025. [Online]. Available: <https://arxiv.org/abs/2503.07465>
 - [18] Y. Kang, J. Hauswald, C. Gao, A. Rovinski, T. Mudge, J. Mars, and L. Tang, “Neurosurgeon: Collaborative intelligence between the cloud and mobile edge.” New York, NY, USA: Association for Computing Machinery, 2017. [Online]. Available: <https://doi.org/10.1145/3037697.3037698>
 - [19] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, “Masked-attention mask transformer for universal image segmentation,” 2022. [Online]. Available: <https://arxiv.org/abs/2112.01527>
 - [20] A. Kirillov, K. He, R. Girshick, C. Rother, and P. Dollár, “Panoptic segmentation,” 2019. [Online]. Available: <https://arxiv.org/abs/1801.00868>
 - [21] B. Hariharan, P. Arbeláez, R. Girshick, and J. Malik, “Simultaneous detection and segmentation,” 2014. [Online]. Available: <https://arxiv.org/abs/1407.1808>
 - [22] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” 2015. [Online]. Available: <https://arxiv.org/abs/1505.04597>
 - [23] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.00020>
 - [24] F. Liang, B. Wu, X. Dai, K. Li, Y. Zhao, H. Zhang, P. Zhang, P. Vajda, and D. Marculescu, “Open-vocabulary semantic segmentation with mask-adapted clip,” 2023. [Online]. Available: <https://arxiv.org/abs/2210.04150>
 - [25] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, “Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter,” 2020. [Online]. Available: <https://arxiv.org/abs/1910.01108>

Anexa A. Secțiuni relevante din cod

```
/** Maps are easy to use in Scala. */
object Maps {
  val colors = Map("red" -> 0xFF0000,
                   "turquoise" -> 0x00FFFF,
                   "black" -> 0x000000,
                   "orange" -> 0xFF8040,
                   "brown" -> 0x804000)

  def main(args: Array[String]) {
    for (name <- args) println(
      colors.get(name) match {
        case Some(code) =>
          name + " has code: " + code
        case None =>
          "Unknown color: " + name
      }
    )
  }
}
```

Anexa B. Alte informații relevante (demonstrații etc.)

Se va elimina dacă nu există

Anexa C. Lucrări publicate (dacă există)

Se va elimina dacă nu există